

Databricks Data-Engineering-Plattform & Lakeflow im Überblick

Section 1 · Databricks Intelligence Plattform · Quelle: Kurs 1 & Kurs 2, jeweils Lektion 1


Dieses Dokument bildet den Einstieg in die gesamte Dokumentationsreihe. Es beantwortet drei Fragen: Was ist die Databricks-Plattform eigentlich, wie organisiert sie Daten intern (Medallion-Architektur und Unity Catalog), und wie hängen die sechs folgenden Sections mit dem Databricks-Produkt **Lakeflow** zusammen. Wer diese Landkarte im Kopf hat, kann die Detail-PDFs der übrigen Sections deutlich leichter einordnen.

1. Die Databricks Data Intelligence Plattform

Databricks ist im Kern eine **Lakehouse-Plattform**: Sie kombiniert die Kostenvorteile und Flexibilität eines Data Lakes (offene Dateiformate, beliebig skalierbarer Cloud-Speicher) mit den Verlässlichkeitsgarantien eines klassischen Data Warehouse (Transaktionssicherheit, Schema-Durchsetzung, schnelle SQL-Abfragen). Möglich wird das durch **Delta Lake**, ein offenes Tabellenformat, das auf Parquet-Dateien aufsetzt und zusätzlich ein JSON-basiertes Transaktionsprotokoll (den *Delta Log*) mitführt. Dieses Protokoll verleiht sogenannten **Delta-Tabellen** Eigenschaften, die man sonst nur aus Datenbanken kennt:

- **ACID-Transaktionen** – mehrere Nutzer können gleichzeitig lesen und schreiben, ohne dass sich Änderungen gegenseitig zerstören.
- **DML-Unterstützung** – `INSERT`, `UPDATE`, `DELETE` und `MERGE` funktionieren wie in einer relationalen Datenbank.
- **Time Travel** – frühere Tabellenversionen lassen sich abfragen oder wiederherstellen.
- **Schema-Enforcement & -Evolution** – das Schema wird beim Schreiben geprüft, kann bei Bedarf aber kontrolliert erweitert werden.

Auf dieser Speicherschicht setzt Databricks zwei weitere Säulen auf: **Unity Catalog** für die einheitliche Governance (siehe Kapitel 3 sowie Section 7) und **Lakeflow** für Ingestion, Transformation und Orchestrierung (siehe Kapitel 4 sowie Sections 2–4). Als Verarbeitungs-Engine kommt durchgängig Apache Spark inklusive Structured Streaming zum Einsatz, beschleunigt durch die proprietäre **Photon**-Engine – Details dazu in Section 6.



Die Databricks Data Intelligence Platform: optimierter Speicher (Delta Lake/Parquet/Iceberg), einheitliche Governance (Unity Catalog) und Lakeflow als Klammer um Connect, Pipelines und Jobs.

2. Medallion-Architektur: Bronze, Silver, Gold


Daten werden in Databricks typischerweise nicht in einem Schritt von der Rohquelle zur fertigen Kennzahl verarbeitet, sondern durchlaufen mehrere aufeinander aufbauende Qualitätsstufen – die sogenannte **Medallion-Architektur**, gelegentlich auch als **Multi-Hop-Architektur** bezeichnet, da die Daten schrittweise mehrere „Hops“ (Stufen) durchlaufen:

- **Bronze** – Rohdaten, so wie sie aus der Quelle kommen (Dateien, Datenbank-Exporte, API-Antworten). Es findet kaum Transformation statt, damit die Ursprungsdaten jederzeit nachvollziehbar bleiben.
- **Silver** – bereinigte, validierte und angereicherte Daten. Duplikate werden entfernt, Typen korrigiert, Tabellen aus mehreren Quellen zusammengeführt.
- **Gold** – aggregierte, geschäftsfertige Daten, meist bereits auf die Anforderungen von BI-Dashboards, Machine-Learning-Modellen oder operativen Anwendungen zugeschnitten.

Jede Stufe kann sowohl aus Batch- als auch aus Streaming-Quellen gespeist werden; der zentrale Vorteil ist, dass Datenqualität und Nutzbarkeit mit jeder Stufe steigen, während gleichzeitig die Rohdaten der Bronze-Schicht als Fallback erhalten bleiben. Die wichtigsten Vorteile dieses Musters im Überblick:

- **Einfaches, verständliches Datenmodell** – drei klar abgegrenzte Stufen statt einer unübersichtlichen Vielzahl von Ad-hoc-Transformationen.
- **Inkrementelles ETL** – jede Stufe verarbeitet nur die seit dem letzten Lauf neu hinzugekommenen Daten, statt bei jedem Durchlauf alles neu zu berechnen.

- **Batch und Streaming in derselben Pipeline kombinierbar** – jede einzelne Stufe lässt sich unabhängig als Batch- oder Streaming-Job konfigurieren.
- **Tabellen jederzeit aus den Rohdaten rekonstruierbar** – da Bronze die unveränderten Ursprungsdaten dauerhaft aufbewahrt, lassen sich Silver und Gold bei Bedarf (z. B. nach einem Fehler in der Transformationslogik) komplett neu aus Bronze berechnen.



Bronze → Silver → Gold: Rohdaten werden schrittweise bereinigt, angereichert und für Reporting, ML/KI und Streaming-Analysen aufbereitet.

3. Unity Catalog: die Governance-Ebene

Unity Catalog ist die zentrale Verwaltungsschicht für alle Daten- und KI-Objekte im Workspace – unabhängig davon, ob es sich um Tabellen, Dateien, Machine-Learning-Modelle oder Dashboards handelt. Er stellt Zugriffskontrolle, Auditing, Data Lineage, Datenqualitäts-Monitoring und Discoverability über beliebig viele Workspaces hinweg bereit. Die Objekte sind hierarchisch organisiert:

Ebene	Bedeutung
Metastore	Oberste Ebene pro Cloud-Region; enthält die Metadaten aller Catalogs. In der Regel ein Metastore pro Organisation/Region.
Catalog	Oberste Organisationseinheit für Daten, z. B. getrennt nach Umgebung (dev , prod) oder Geschäftsbereich.
Schema (Database)	Gruppiert zusammengehörige Tabellen, Views und Volumes innerhalb eines Catalogs, ähnlich einem Datenbankschema.
Table / View	Die eigentlichen strukturierten Daten – als Managed Table (Databricks verwaltet Daten und Metadaten) oder External Table (nur Metadaten werden verwaltet).
Volume	Governed Zugriff auf nicht-tabellarische Dateien (z. B. Rohdateien vor der Ingestion, Bilder, Modell-Artefakte).

Der vollqualifizierte Name eines Objekts folgt entsprechend dem Muster `catalog.schema.table`, z. B. `prod.sales.orders_gold`. Zugriffsrechte werden über Standard-SQL-Befehle wie `GRANT SELECT ON TABLE ... TO ...` vergeben und lassen sich bis auf Zeilen- und Spaltenebene verfeinern (siehe Section 7 – Governance and Security).

4. Lakeflow: die Landkarte für Ingestion, Transformation und Orchestrierung

Lakeflow ist die Sammelbezeichnung für Databricks' integrierte Data-Engineering-Werkzeuge. Es besteht aus drei (inzwischen vier) Kernkomponenten, die inhaltlich genau den ersten Themenordnern dieser Dokumentationsreihe entsprechen:

- **Lakeflow Connect** – effiziente Ingestion-Connectoren, mit denen Daten aus Cloud-Speicher, Datenbanken, SaaS-Anwendungen (z. B. Salesforce, SharePoint) und Message-Bussen (z. B. Kafka) in die Lakehouse-Plattform gelangen. Batch, inkrementelles Batch und Streaming werden dabei einheitlich unterstützt.
- **Lakeflow Pipelines** (früher *Delta Live Tables*, technisch als *Spark Declarative Pipelines* bezeichnet) – ein deklaratives Framework für Batch- und Streaming-ETL in SQL und Python. Statt einzelne Verarbeitungsschritte manuell zu orchestrieren, beschreibt man nur das gewünschte Ergebnis (Streaming Tables, Materialized Views); Databricks kümmert sich um Ausführungsreihenfolge, Fehlerbehandlung und inkrementelle Aktualisierung.
- **Lakeflow Jobs** – die Orchestrierungsschicht, mit der beliebige Workloads (Notebooks, SQL-Abfragen, Pipelines, ML-Trainings) zu Workflows mit Abhängigkeiten, Zeitplänen und Benachrichtigungen kombiniert werden – als native Alternative zu externen Tools wie Apache Airflow.
- **Lakeflow Designer** – eine neuere, no-code/low-code Oberfläche, mit der auch Analysten ohne Programmierkenntnisse per Drag-and-drop und natürlichsprachlichen Prompts produktionsreife ETL-Pipelines erstellen können.

So sind die Sections dieser Dokumentation aufgebaut

Section	Thema	Lakeflow-/Plattform-Bezug
1	Databricks Intelligence Plattform	Dieses Dokument – Lakehouse-Grundlagen, Medallion-Architektur, Unity Catalog, Lakeflow-Landkarte
2	Data Ingestion and Loading	Connect – Batch-/Streaming-Ingestion, Metadaten, Enterprise-Connectoren, MERGE INTO

3	Data Transformation and Modelling	Pipelines – Streaming Tables, Materialized Views, Expectations, Multi-Flow, Liquid Clustering, Delta Sinks, CDC (SCD Type 1 & 2)
4	Working with Lakeflow Jobs	Jobs – Tasks, Scheduling, bedingte/iterative Tasks, Monitoring, Best Practices
5	Implementing CI/CD	Software Engineering & Deployment – Modularisierung, Unit-/Integrationstests, Git, Asset Bundles, Multi-Environment-Deployments
6	Troubleshooting, Monitoring and Optimization	Spark-Engine – AQE, Data Skipping, Liquid Clustering, Skew/Shuffle/Spill, Cluster-Auswahl/Photon
7	Governance and Security	Unity Catalog – ACLs, Row Filters/Column Masks, PII-Schutz, CDF, DSGVO/CCPA

Kurz gesagt: Section 2–4 behandeln die drei klassischen Lakeflow-Komponenten (Connect, Pipelines, Jobs), Section 6–7 vertiefen die darunterliegenden Plattfordmdienste (Performance, Governance), und Section 5 zeigt, wie man all das softwaretechnisch sauber entwickelt, testet und produktiv ausrollt – von der ersten Unit-Test-Zeile bis zum automatisierten Asset-Bundle-Deployment.

Ergänzt aus der offiziellen Databricks-Dokumentation: Seit 2025 zählt neben Connect, Pipelines und Jobs auch **Lakeflow Designer** offiziell zu Lakeflow – eine visuelle, KI-gestützte No-Code-Oberfläche, mit der auch Fachanwender ohne Python-/SQL-Kenntnisse Pipelines per Drag-and-drop und natürlichsprachlichen Prompts bauen können. Der frühere Produktname „Delta Live Tables“ wurde vollständig durch **Lakeflow Pipelines** (technisch: Spark Declarative Pipelines) ersetzt; die zugrunde liegenden Konzepte (Streaming Tables, Materialized Views, Expectations) sind unverändert geblieben.

Quelle: [Data engineering with Databricks – Databricks-Dokumentation](#), [Introducing Databricks Lakeflow – Databricks Blog](#)