

Apache Spark auf Databricks – Übersicht

Diese Seite ist der zentrale Einstiegspunkt in die Spark-Dokumentation von Databricks. Sie erklärt, wie Apache Spark und Databricks zusammenhängen, und verlinkt auf alle wichtigen Unterthemen. Sie ist ein guter erster Anlaufpunkt, wenn man verstehen möchte, wie die Databricks-Plattform „unter der Haube“ funktioniert.

Was ist Apache Spark – und welche Rolle spielt es bei Databricks?

Apache Spark ist die Technologie, die die Rechen-Cluster (Compute Clusters) und SQL-Warehouses von Databricks antreibt. Vereinfacht gesagt: Immer wenn in Databricks Code ausgeführt wird – ob eine Abfrage, ein Notebook oder ein Job – arbeitet im Hintergrund Apache Spark als Rechen-Engine. Databricks wurde ursprünglich von den Entwicklern von Apache Spark gegründet, daher ist die Integration besonders eng.

Einstieg für Neulinge

Für den Einstieg in Spark auf Databricks bietet die Dokumentation drei Wege an:

- **Häufig gestellte Fragen (FAQ):** Grundlegende Fragen zum Zusammenspiel von Spark und Databricks.
- **Tutorial „Daten laden und transformieren mit Spark DataFrames“:** Ein praktisches Tutorial, verfügbar für Python, R und Scala.
- **PySpark-Grundlagen:** Ein Einstieg in die Python-Schnittstelle von Spark mit praktischen Beispielen.

Weiterführende Themen

Für Nutzer, die tiefer einsteigen möchten, verlinkt die Übersichtsseite auf folgende Themenbereiche – jedes davon wird in dieser Kursdokumentation als eigenes PDF behandelt:

- **Spark Connect vs. Spark Classic:** Zwei verschiedene Architekturen, wie eine Anwendung mit dem Spark-Cluster kommuniziert.
- **Spark-Konfigurationseigenschaften:** Wie man Spark-Einstellungen auf Databricks anpasst (und wann man das besser lässt).

- **Spark API-Optionen (Referenz):** Eine Nachschlage-Referenz für alle Optionen beim Lesen und Schreiben von Daten.
- **Structured Streaming:** Die Streaming-Engine von Spark für die Verarbeitung kontinuierlicher Datenströme.
- **Spark UI:** Ein Web-Interface zur Diagnose von Kosten- und Performance-Problemen.
- **Apache Spark MLlib:** Die Bibliothek für verteiltes maschinelles Lernen.
- **Referenz für Apache Spark APIs:** Übersicht über die APIs in den verschiedenen Programmiersprachen.

Spark-APIs nach Programmiersprache

Apache Spark lässt sich aus mehreren Sprachen heraus nutzen. Databricks bietet dazu jeweils eigene Leitfäden an:

Sprache / API	Kurzbeschreibung
PySpark	Die Python-Schnittstelle zu Spark – in der Praxis die meistgenutzte Variante.
Pandas API on Spark	Ermöglicht die aus pandas bekannte Syntax auf großen, verteilten Datenmengen.
R für Spark (SparkR / sparklyr)	Schnittstellen, um Spark aus R heraus zu nutzen.
Scala für Spark	Scala ist die Sprache, in der Spark selbst geschrieben ist, und bietet vollen Funktionsumfang.

Warum ist das wichtig?

Wer mit Databricks arbeitet, sollte zumindest die Grundzüge von Apache Spark verstehen: Wie Daten verteilt verarbeitet werden, warum Operationen erst „verzögert“ (lazy) ausgeführt werden und welche Werkzeuge (z. B. die Spark UI) zur Fehlersuche und Optimierung zur Verfügung stehen. Diese Übersichtsseite dient als Landkarte für alle weiteren, spezialisierten Themen.

Quelle: <https://docs.databricks.com/aws/en/spark/>
Stand: 2026-08-06