

Apache Spark auf Databricks – Häufig gestellte Fragen

Diese Seite beantwortet grundlegende Fragen zum Zusammenspiel von Apache Spark und Databricks. Sie eignet sich gut, um zu verstehen, was Databricks eigentlich zu „reinem“ Apache Spark hinzufügt und wie Spark im Alltag auf der Plattform genutzt wird.

Wie hängen Apache Spark und Databricks zusammen?

Databricks wurde von den ursprünglichen Entwicklern von Apache Spark gegründet. Das Unternehmen trägt bis heute aktiv zur Weiterentwicklung des Open-Source-Projekts bei. Die auf Databricks eingesetzte Databricks Runtime ist im Kern Apache Spark, ergänzt um zusätzliche Optimierungen und proprietäre Funktionen, die es in der freien Version nicht gibt.

Was optimiert Databricks gegenüber reinem Apache Spark?

Ein zentrales Element ist **Photon**, eine speziell entwickelte, hochoptimierte Ausführungsebene (Execution Engine), die Abfragen deutlich beschleunigt. Photon ersetzt intern Teile der Standard-Spark-Verarbeitung, ohne dass Nutzer ihren Code ändern müssen.

Ein weiterer wichtiger Baustein ist das **Lazy-Execution-Modell**: Spark führt Berechnungen nicht sofort aus, sondern baut zunächst einen Ausführungsplan auf. Dabei unterscheidet man zwei Arten von Operationen:

- **Transformationen** – z. B. Daten einlesen, Joins durchführen, Aggregationen definieren. Diese werden nur „vorgemerkt“, aber noch nicht ausgeführt.
- **Aktionen** – z. B. Ergebnisse anzeigen oder Daten schreiben. Erst eine Aktion löst die tatsächliche Verarbeitung aus.

Weil Databricks die komplette Kette aus Transformationen und Aktionen kennt, kann die Plattform den gesamten Ablauf ganzheitlich optimieren, statt nur einzelne Schritte zu betrachten.

Wie läuft Spark technisch auf Databricks?

Apache Spark wird auf virtuellen Maschinen (Compute-Clustern) bereitgestellt, die Databricks im Hintergrund verwaltet. Ein wichtiger Vorteil für Einsteiger: Man muss den sogenannten *Spark*

Context oder die *Spark Session* – also die zentralen Einstiegspunkte in eine Spark-Anwendung – nicht selbst konfigurieren. Databricks übernimmt das automatisch, sodass man sich auf die eigentliche Datenverarbeitung konzentrieren kann.

Kann man Databricks auch ohne Spark nutzen?

Ja. Databricks unterstützt auch Workloads, die nicht direkt auf Spark aufsetzen – zum Beispiel Machine-Learning-Aufgaben mit Bibliotheken wie TensorFlow oder scikit-learn sowie weitere gängige Open-Source-Werkzeuge. Spark ist also die zentrale, aber nicht die einzige Verarbeitungs-Engine der Plattform.

Welche Vorteile bietet Databricks gegenüber einem selbst betriebenen Spark-Cluster?

Databricks stellt eine sichere, kollaborative Umgebung bereit, die für den unternehmensweiten Einsatz gedacht ist. Dazu gehören kontinuierliche Performance-Optimierungen, verwaltete Infrastruktur und die Integration verschiedener Werkzeuge (Notebooks, Jobs, Governance) in einer Plattform – Dinge, die man beim eigenständigen Betrieb von Spark selbst aufbauen müsste.

Quelle: <https://docs.databricks.com/aws/en/spark/faq>

Stand: 2026-08-06