

Referenz für Apache Spark APIs

Apache Spark bietet für unterschiedliche Programmiersprachen eigene APIs an, mit denen man auf die gleichen Grundkonzepte (SparkSession, DataFrame, Dataset) zugreifen kann. Diese Seite dient als Wegweiser: Sie zeigt, welche zentralen Objekte es in welcher Sprache gibt und wo man die jeweilige offizielle Dokumentation findet.

Grundkonzepte, die in allen Sprachen wiederkehren

- **SparkSession:** Der zentrale Einstiegspunkt in eine Spark-Anwendung. Über die SparkSession greift man auf alle weiteren Spark-Funktionen zu.
- **DataFrame:** Eine verteilte Sammlung von Daten, organisiert in benannten Spalten – vergleichbar mit einer Tabelle in einer Datenbank oder einem Excel-Blatt, nur dass die Daten über mehrere Rechner verteilt gespeichert und verarbeitet werden.
- **Dataset:** Eine stark typisierte Sammlung von Objekten mit einem bestimmten, klar definierten Datentyp (nur in Scala und Java verfügbar). Ein DataFrame ist im Kern nichts anderes als eine "untypisierte" Sicht auf ein Dataset.

APIs nach Sprache im Überblick

PySpark (Python)

Die Python-Schnittstelle zu Spark. Zentrale Objekte sind die `SparkSession` als Einstiegspunkt sowie das `DataFrame`, das in PySpark über **mehr als 100 verschiedene Operatoren** verfügt (z. B. zum Filtern, Gruppieren, Verknüpfen und Transformieren von Daten).

Scala

Scala ist die Sprache, in der Spark selbst entwickelt wurde, und bietet daher den vollständigsten Zugriff auf alle Funktionen. Zentrale Objekte sind `SparkSession` und `Dataset` (stark typisiert). Ein `DataFrame` ist hier technisch gesehen ein `Dataset[Row]`, also eine untypisierte Variante des Datasets.

Java

Auch für Java stehen `SparkSession` und `Dataset` zur Verfügung. Java-Anwendungen werden auf Databricks typischerweise über JAR-basierte Jobs ausgeführt, nicht interaktiv im Notebook.

SparkR (R) – als veraltet markiert

Für R gibt es ebenfalls eine `SparkSession` als Einstiegspunkt sowie das `SparkDataFrame` als verteilte Datensammlung mit benannten Spalten. Hinweis: SparkR gilt mittlerweile als veraltet (siehe eigenes Kapitel zu R für Spark).

Gemeinsames Prinzip: Parallele, verteilte Verarbeitung

Unabhängig von der gewählten Sprache verarbeitet Spark Daten grundsätzlich parallel und verteilt über mehrere Rechenknoten. DataFrame-Operationen lassen sich dabei entweder funktional (Methodenaufrufe wie `filter()`, `groupBy()`) oder relational (SQL-artige Abfragen) formulieren – beide Wege führen intern zum gleichen Ausführungsplan.

Weiterführende Ressourcen

Die Seite verlinkt auf Tutorials, sprachspezifische Leitfäden sowie auf die offizielle Apache-Spark-Dokumentation, dazu auf die Databricks Community und die Knowledge Base für weiterführende Hilfe.

Einordnung für Einsteiger

Wer neu bei Spark ist, sollte sich zunächst für eine Sprache entscheiden (in der Praxis meist Python/PySpark oder SQL) und die Grundobjekte `SparkSession` und `DataFrame` verstehen. Die anderen Sprach-APIs folgen alle demselben Grundmuster, sodass sich Wissen gut übertragen lässt, sobald man die Konzepte einmal verinnerlicht hat.

Quelle: <https://docs.databricks.com/aws/en/reference/spark>
Stand: 2026-08-06