

Spark UI – Kosten- und Performance-Probleme diagnostizieren

Die Spark UI ist ein Web-Interface, das direkt in jedem Databricks-Cluster eingebaut ist. Sie zeigt im Detail, was Spark intern tut – welche Jobs laufen, wie lange einzelne Schritte dauern und wo möglicherweise Engpässe entstehen. Diese Seite ist ein praktischer Leitfaden, wie man mit der Spark UI systematisch Performance- und Kostenprobleme aufspürt, statt sich im Dickicht der vielen angezeigten Kennzahlen zu verlieren.

Voraussetzung: Grundverständnis der Spark-Architektur

Um die Spark UI sinnvoll zu nutzen, sollte man die grundlegenden Bausteine einer Spark-Anwendung kennen:

- **Driver:** Der Koordinator einer Spark-Anwendung, der den Ausführungsplan erstellt und die Arbeit auf die Worker verteilt.
- **Worker / Executor:** Die Rechenknoten, die die eigentliche Arbeit (Tasks) ausführen.
- **Stage:** Ein Abschnitt der Verarbeitung, der aus mehreren parallel laufenden Tasks besteht.
- **Task:** Die kleinste Verarbeitungseinheit, die auf einem Datenteil (Partition) läuft.

Zugang zur Spark UI

Man erreicht die Spark UI über die Cluster-Seite des jeweiligen Clusters: Dort klickt man auf die Option "Spark UI", um das Web-Interface für diesen Cluster zu öffnen.

Der fünfstufige Diagnose-Prozess

Der Leitfaden empfiehlt ein systematisches Vorgehen in fünf Schritten, um die Ursache eines Performance-Problems einzugrenzen:

1. **Jobs-Zeitleiste analysieren:** Zunächst verschafft man sich einen Überblick über alle Jobs und deren zeitlichen Verlauf, um größere, auffällige Probleme zu identifizieren (z. B. einen einzelnen Job, der ungewöhnlich lange dauert).

2. **Die längste Stage untersuchen:** Innerhalb des auffälligen Jobs wird die Stage (der Verarbeitungsabschnitt) identifiziert, die am längsten braucht – dort liegt meist das eigentliche Problem.
3. **Nach Datenschiefe oder Speicherüberlauf suchen:** Man prüft, ob die Daten ungleichmäßig auf die Tasks verteilt sind ("Data Skew" – manche Tasks bekommen viel mehr Daten als andere) oder ob Daten wegen Speichermangels auf die Festplatte ausgelagert werden mussten ("Spill").
4. **Prüfen, ob die Stage I/O-gebunden ist:** Es wird untersucht, ob die lange Laufzeit hauptsächlich am Lesen/Schreiben von Daten liegt (Input/Output), statt an der eigentlichen Berechnung.
5. **Weitere Ursachen identifizieren:** Falls die vorherigen Schritte keine klare Antwort liefern, werden weitere mögliche Gründe für langsame Stage-Laufzeiten untersucht.

Weiterführende Ressourcen

Die Seite verweist für eine umfassendere Behandlung von Optimierungsthemen auf den "Databricks Optimization Guide", der zusätzliche Werkzeuge und Techniken zur Performance-Verbesserung beschreibt.

Warum das für den Alltag wichtig ist

Gerade bei der Arbeit mit großen Datenmengen ist es fast unvermeidlich, irgendwann auf langsame oder teure Abfragen zu stoßen. Die Spark UI ist dabei das wichtigste eingebaute Werkzeug, um solche Probleme selbst zu analysieren, statt blind an Konfigurationswerten herumzuprobieren. Der systematische Fünf-Schritte-Ansatz hilft dabei, nicht in der Fülle der angezeigten Informationen unterzugehen, sondern gezielt von der groben zur genauen Ursache vorzudringen.

Quelle: <https://docs.databricks.com/aws/en/optimizations/spark-ui-guide/>
Stand: 2026-08-06