

Apache Spark MLlib auf Databricks

MLlib ist die Bibliothek von Apache Spark für verteiltes maschinelles Lernen. Sie stellt gängige Lernalgorithmen und Hilfswerkzeuge bereit, die – anders als viele klassische ML-Bibliotheken – von Grund auf dafür gebaut sind, mit großen, über mehrere Rechner verteilten Datenmengen umzugehen. Diese Seite gibt einen Überblick, welche Funktionen MLlib bietet und wo man praktische Beispiele findet.

Was ist MLlib?

MLlib wird in der Dokumentation als "machine learning library consisting of common learning algorithms and utilities" beschrieben – also eine Bibliothek gängiger Lernalgorithmen und Hilfsfunktionen. Auf Databricks steht dafür vor allem das Python-Paket `pyspark.ml` zur Verfügung, das auf Serverless Compute, Standard-Compute und dedizierten Compute-Optionen gleichermaßen genutzt werden kann.

Unterstützte Funktionsbereiche

MLlib deckt die klassischen Kernbereiche des maschinellen Lernens ab:

- **Klassifizierung:** Vorhersage einer Kategorie (z. B. "Spam" oder "kein Spam").
- **Regression:** Vorhersage eines numerischen Werts (z. B. ein Preis oder eine Menge).
- **Clustering:** Automatisches Gruppieren ähnlicher Datenpunkte ohne vorgegebene Kategorien.
- **Collaborative Filtering:** Grundlage für Empfehlungssysteme, z. B. "Nutzer, die X mochten, mochten auch Y".
- **Dimensionalitätsreduktion:** Verringerung der Anzahl an Merkmalen (Features) in einem Datensatz, ohne wichtige Information zu verlieren.
- **Optimierungsprimitiven:** Grundlegende mathematische Bausteine, auf denen viele der oben genannten Algorithmen aufbauen.

Praktische Beispiele aus der Dokumentation

Binäre Klassifizierung mit der Pipelines-API

Ein Beispiel zeigt, wie man mit der MLLib-**Pipelines-API** eine binäre Klassifizierungsaufgabe löst. Pipelines fassen mehrere Verarbeitungsschritte (z. B. Datenvorbereitung, Feature-Erstellung, Training) zu einem einheitlichen, wiederverwendbaren Ablauf zusammen.

Entscheidungsbäume

Zwei praktische Notebooks demonstrieren Entscheidungsbäume (Decision Trees):

- Ziffernerkennung (Erkennung handgeschriebener Zahlen)
- Analyse einer Umfrage vom Flughafen San Francisco (SFO)

Gradient Boosted Trees (GBT) für Regression

Ein weiteres Beispiel nutzt MLLib-Pipelines mit Gradient Boosted Trees, um die Anzahl an Fahrradvermietungen anhand von Wetterdaten und Wochentag vorherzusagen – ein klassisches Regressionsproblem.

Custom Transformer

Für fortgeschrittene Nutzer zeigt ein Beispiel, wie man einen eigenen, maßgeschneiderten Transformer erstellt – also einen eigenen Verarbeitungsschritt, der sich nahtlos in eine MLLib-Pipeline einfügen lässt.

Weiterführende Referenzen

Die Seite verlinkt auf die offiziellen Apache-Spark-API-Dokumentationen für Python, Scala und Java sowie auf zusätzliche Ressourcen für maschinelles Lernen mit R.

Einordnung: Wann lohnt sich MLLib?

MLLib ist vor allem dann sinnvoll, wenn Trainingsdaten so groß sind, dass sie nicht mehr auf einem einzelnen Rechner verarbeitet werden können, oder wenn ein Modell ohnehin schon im Rahmen einer größeren Spark-Datenpipeline trainiert werden soll. Für kleinere Datenmengen, die bequem in den Arbeitsspeicher eines einzelnen Rechners passen, sind oft klassische Bibliotheken wie scikit-learn einfacher zu handhaben – Databricks unterstützt, wie in der FAQ erwähnt, auch solche nicht-verteilten ML-Workloads.

Quelle: <https://docs.databricks.com/aws/en/machine-learning/train-model/mllib>

Stand: 2026-08-06