

Pandas API on Spark

Viele Data-Scientists kennen und schätzen die Python-Bibliothek pandas für die Analyse von Tabellendaten. Ihr großes Problem: pandas läuft nur auf einem einzelnen Rechner und skaliert nicht auf sehr große Datenmengen. Die "Pandas API on Spark" schließt genau diese Lücke – sie bietet dieselbe vertraute pandas-Syntax, führt die Berechnungen aber verteilt über einen Spark-Cluster aus.

Das Grundproblem, das gelöst wird

pandas ist eines der beliebtesten Werkzeuge für Datenanalyse in Python, stößt aber bei großen Datenmengen an seine Grenzen, weil es Daten im Arbeitsspeicher eines einzelnen Rechners hält und verarbeitet. Die Pandas API on Spark bietet – wörtlich – "pandas equivalent APIs that work on Apache Spark", also zu pandas gleichwertige (äquivalente) Programmierschnittstellen, die auf Apache Spark laufen. Dadurch lässt sich bekannter pandas-Code mit vergleichsweise wenig Anpassung auf große, verteilte Datenmengen anwenden.

Wichtige Unterschiede zu klassischem pandas

Aspekt	Erklärung
Skalierbarkeit	Funktioniert auch mit sehr großen Datenmengen, da im Hintergrund Apache Spark die Verteilung übernimmt
Erweiterte Funktionen	Unterstützt manche Aufgaben, die mit reinem PySpark umständlicher wären – z. B. direkte Datenvisualisierung aus einem DataFrame heraus
Zielgruppe	Nützlich sowohl für erfahrene pandas-Nutzer, die auf große Datenmengen skalieren möchten, als auch für PySpark-Nutzer, die eine vertrautere Syntax bevorzugen

Voraussetzungen und Einbindung

- Benötigt mindestens Apache Spark 3.2 oder neuer.
- Ist bereits ab Databricks Runtime 10.0 standardmäßig enthalten.
- Import in Python: `import pyspark.pandas as ps`

- Für ältere Databricks-Runtime-Versionen (9.1 LTS und früher) muss stattdessen die Vorgänger-Bibliothek **Koalas** verwendet werden, aus der die Pandas API on Spark hervorgegangen ist.

Weiterführende Ressourcen

Die Dokumentation verweist auf einen Migrationsleitfaden für den Umstieg von klassischem pandas, auf offizielle Benutzerhandbücher und API-Referenzen sowie auf ein Jupyter-Notebook mit praktischen Beispielen.

Wann sollte man die Pandas API on Spark einsetzen?

Sinnvoll ist dieser Ansatz vor allem dann, wenn bereits vorhandener pandas-Code auf größere Datenmengen skaliert werden soll, ohne die Logik komplett auf reines PySpark umzuschreiben. Für sehr kleine Datenmengen, die problemlos in den Arbeitsspeicher eines einzelnen Rechners passen, bringt klassisches pandas dagegen oft weniger Overhead und ist die einfachere Wahl.

Quelle: <https://docs.databricks.com/aws/en/pandas/pandas-on-spark>

Stand: 2026-08-06