

Databricks-Architektur: Überblick

Diese Seite ist der Einstiegspunkt in das Thema "Databricks-Architektur". Sie fasst zusammen, welche Themen in diesem Kapitel behandelt werden, und verweist auf die vertiefenden Einzeldokumente. Sie richtet sich an alle, die verstehen wollen, wie Databricks technisch aufgebaut ist und wie das Lakehouse-Konzept in der Praxis funktioniert.

Das Kapitel gliedert sich in zwei große Themenblöcke: zum einen die **Plattform-Architektur** (wie Databricks technisch aufgebaut ist, welche Komponenten es gibt und wie man eine Databricks-Umgebung sinnvoll plant), zum anderen die **Lakehouse-Konzepte** (wie Daten in einem Lakehouse organisiert, geschützt und gemeinsam genutzt werden).

Teil 1: Plattform-Architektur

Dieser Block erklärt, wie Databricks als Plattform aufgebaut ist und wie man eine Databricks-Umgebung in der Cloud plant.

High-Level-Architektur

Beschreibt den grundlegenden Bauplan von Databricks: die Trennung zwischen **Control Plane** (von Databricks verwaltete Backend-Dienste) und **Compute Plane** (dort, wo die eigentliche Datenverarbeitung stattfindet). Außerdem wird erklärt, wie Accounts, Workspaces und der Unity-Catalog-Metastore zusammenhängen und wie Speicher organisiert ist.

Well-Architected Framework

Ein Leitfaden mit Best Practices, um eine Databricks-Umgebung zuverlässig, sicher, effizient und kosteneffektiv aufzubauen. Er bündelt Grundprinzipien, Referenzarchitekturen und einen schrittweisen Deployment-Guide.

Referenzarchitekturen

Fertige Architektur-Blaupausen (als Diagramme) für typische Anwendungsfälle wie Batch-Ingestion, Streaming, Machine Learning, BI/SQL-Analytics oder Data Sharing – jeweils mit den passenden AWS- und Databricks-Komponenten.

Teil 2: Lakehouse-Konzepte

Dieser Block erklärt die zentralen Ideen hinter dem "Lakehouse" – der Kombination aus Data Lake (günstiger, flexibler Objektspeicher) und Data Warehouse (Struktur, Transaktionssicherheit, Governance).

ACID-Garantien

Erklärt, wie Databricks über Delta Lake dieselben Transaktionsgarantien bietet, die man aus klassischen Datenbanken kennt (Atomarität, Konsistenz, Isolation, Dauerhaftigkeit) – obwohl die Daten eigentlich in einem einfachen Objektspeicher wie S3 liegen.

Medallion-Architektur

Ein bewährtes Muster, um Daten in drei Qualitätsstufen zu organisieren: **Bronze** (Rohdaten), **Silver** (bereinigte, validierte Daten) und **Gold** (aggregierte, geschäftsfertige Daten).

Single Source of Truth

Erklärt, wie das Lakehouse verhindert, dass Daten in mehreren Kopien mit unterschiedlichem Stand in der Organisation existieren – und wie Unity Catalog dabei die Zugriffssteuerung übernimmt.

Data Discovery & Collaboration

Beschreibt, wie Teams im Lakehouse Daten finden (Catalog Explorer), sicher austauschen und gemeinsam mit unterschiedlichen Werkzeugen (SQL, Python, Scala, R) daran arbeiten können.

Warum das wichtig ist

Wer diese Grundlagen versteht, kann besser einschätzen, warum Databricks bestimmte Empfehlungen ausspricht (z. B. "nutze die Medallion-Architektur" oder "verwalte Zugriffsrechte über Unity Catalog"), und trifft fundiertere Entscheidungen beim Aufbau eigener Datenplattformen.

Quelle: <https://docs.databricks.com/aws/en/getting-started/architecture>

Stand: 2026-08-06