

High-Level-Architektur von Databricks

Diese Seite erklärt den grundlegenden technischen Aufbau von Databricks: wie Accounts, Workspaces und Speicher zusammenhängen, und wie die Datenverarbeitung zwischen der von Databricks verwalteten "Control Plane" und der eigentlichen Rechenumgebung ("Compute Plane") aufgeteilt ist. Dieses Grundverständnis hilft, spätere Themen wie Sicherheit, Netzwerk und Kosten besser einzuordnen.

Die Organisationsstruktur: Account, Workspace, Metastore

Databricks ist hierarchisch aufgebaut. Ganz oben steht der **Account** – die zentrale Verwaltungseinheit, über die eine Organisation ihre gesamte Databricks-Nutzung steuert. Ein Account übernimmt vier Kernaufgaben:

- **Identität und Zugriff:** Benutzer, Gruppen, Service Principals, automatische Benutzerverwaltung (SCIM) und Single Sign-On (SSO)
- **Workspace-Verwaltung:** Verwaltung mehrerer Workspaces über verschiedene Regionen hinweg
- **Unity-Catalog-Metastore-Verwaltung:** zentrale Datenverwaltung
- **Nutzungssteuerung:** Abrechnung, Compliance und Richtlinien

Innerhalb eines Accounts gibt es zwei zentrale Objekte:

Workspace

Ein Workspace ist die eigentliche Arbeitsumgebung: der Ort, an dem Nutzer Berechnungen ausführen – zum Beispiel Daten einlesen (Ingestion), interaktiv Daten erkunden, geplante Jobs laufen lassen oder Machine-Learning-Modelle trainieren.

Unity-Catalog-Metastore

Der Metastore ist das zentrale Verwaltungssystem für Datenobjekte wie Tabellen und ML-Modelle. Daten werden dabei in einer dreistufigen Namensstruktur organisiert:

```
<catalog-name>.<schema-name>.<object-name>
```

Ein wichtiger Punkt: Ein einziger Metastore kann mit mehreren Workspaces innerhalb derselben Region verknüpft werden. Das ermöglicht eine einheitliche Sicht auf die Daten und zentral gesteuerte Zugriffsrechte über mehrere Workspaces hinweg.

Control Plane vs. Compute Plane

Das zentrale Architekturprinzip von Databricks ist die Trennung in zwei "Ebenen" (Planes):

Control Plane

Die Control Plane umfasst die Backend-Dienste, die Databricks selbst betreibt – und zwar im Databricks-eigenen Cloud-Account, nicht im Account des Kunden. Hier laufen zum Beispiel die Weboberfläche und die administrative Infrastruktur, die den Workspace steuert.

Compute Plane

Die Compute Plane ist der Ort, an dem die eigentliche Datenverarbeitung stattfindet. Es gibt hier zwei Varianten, je nachdem, welche Art von Rechenressourcen genutzt wird:

Compute-Typ	Wo läuft die Verarbeitung?
Serverless Compute	In einer serverlosen Compute-Plane innerhalb des Databricks-Accounts
Classic Compute	Im AWS-Account des Kunden

Klassische Workspace-Architektur (Classic Compute)

Ein klassischer Workspace benötigt einen zugehörigen S3-Speicher-Bucket, den sogenannten **Workspace Storage Bucket**, der im AWS-Account des Kunden liegt. Dieser Bucket speichert drei Arten von Inhalten:

1. **Workspace-Systemdaten:** interne Daten, die von Databricks-Funktionen erzeugt werden
2. **Unity-Catalog-Workspace-Katalog:** der Standard-Katalog des Workspace, falls Unity Catalog aktiv ist – hier können Nutzer eigene Datenobjekte anlegen
3. **DBFS (veraltet):** ein älteres Dateisystem, erreichbar über den Namensraum `dbfs:/`, inklusive DBFS-Root und sogenannter "Mounts"

Die klassische Compute-Plane läuft vollständig im AWS-Account des Kunden. Das bietet eine natürliche Isolation auf Account-Ebene: Die Rechenressourcen werden innerhalb des virtuellen Netzwerks (Virtual Network) jedes Workspace im AWS-Konto des Kunden erstellt.

Wichtiger Hinweis aus der Original-Dokumentation: Der Workspace-Speicher im eigenen Cloud-Account darf nicht gelöscht oder verändert werden. Ein Databricks-Workspace ist sowohl von seinen Control-Plane-Datenbanken als auch von seinem Workspace-Speicher abhängig, um korrekt zu funktionieren.

Serverlose Workspace-Architektur

Serverlose Workspaces nutzen einen sogenannten **Default Storage** – einen vollständig von Databricks verwalteten Speicherort für interne Workspace-Systemdaten und Unity-Catalog-Datenobjekte. Zusätzlich kann sich der Workspace mit den eigenen Cloud-Speicherorten des Kunden verbinden, um dort auf eigene Kataloge, Tabellen und Datenobjekte zuzugreifen.

Bei serverlosem Compute läuft die Verarbeitung anders: Die Rechenressourcen laufen in einer Compute-Schicht innerhalb des Databricks-eigenen Accounts. Wichtig dabei: Databricks erstellt die serverlose Compute-Plane immer in derselben AWS-Region, in der auch die klassische Compute-Plane des Workspace liegt (diese Region wird bei der Workspace-Erstellung festgelegt).

Netzwerk und Sicherheit bei Serverless Compute

Die serverlose Compute-Plane läuft innerhalb einer Netzwerkgrenze, die speziell für den jeweiligen Workspace gilt. Mehrere Sicherheitsschichten isolieren dabei verschiedene Databricks-Kunden-Workspaces voneinander – und es gibt zusätzliche Netzwerkkontrollen zwischen einzelnen Compute-Clustern desselben Kunden. Der Schutz der Kundendaten beruht also sowohl auf der Trennung zwischen unterschiedlichen Kunden als auch auf Kontrollen innerhalb der Cluster eines einzelnen Kunden.

Workspace-Speicher im Detail

Der Workspace-Speicher lässt sich in zwei Kategorien unterteilen:

Workspace-Dateisystem-Daten

Hier landen Inhalte, die Nutzer über die Databricks-Oberfläche selbst erstellen: Notebooks, SQL-Abfragen, Dashboards, Alerts, mit Git verbundene Repositories, Bibliotheken (z. B. `.whl` - oder `.jar` -Dateien) sowie Konfigurationsdateien.

Workspace-Systemdaten

Das sind intern erzeugte Daten, die zu groß sind, um im Arbeitsspeicher oder in klassischen Datenbanken gehalten zu werden. Beispiele: Ergebnisse von SQL-Abfragen, zwischengespeicherte Abfrageergebnisse, Ergebnisse von Job-Ausführungen, Notebook-Versionsverläufe, SQL-Abfragepläne (für die Beobachtbarkeit/Observability) und Cluster-Logs.

Diese beiden Speicherkategorien sind von den eigentlichen Nutzdaten – also Unity-Catalog-Tabellen und -Volumes – getrennt zu betrachten.

Regionen und Cloud-Flexibilität

Die Architektur unterstützt mehrere Cloud-Anbieter. Diese Seite konzentriert sich auf die AWS-spezifische Umsetzung; grundsätzlich lässt sich Databricks aber auch auf Azure, Google Cloud (GCP) und SAP betreiben.

Kernprinzipien im Überblick

Die Architektur von Databricks folgt drei Leitgedanken:

- **Isolation:** Account-basierte Isolation bei klassischem Compute, netzwerkbasierte Isolation bei serverlosem Compute
- **Governance:** Ein zentraler Metastore ermöglicht konsistente Steuerung über mehrere Workspaces hinweg
- **Flexibilität:** Die Trennung von Control Plane und Compute Plane erlaubt flexibles Ressourcenmanagement und Kostenoptimierung

Diese Architektur erfüllt typische Anforderungen von Unternehmen: mehrere Regionen gleichzeitig nutzen, Governance zentral steuern, Nutzern eine gemeinsame Zusammenarbeitsumgebung bieten und Daten sicher verwalten – dabei werden sowohl ältere Ansätze (DBFS) als auch das moderne Governance-Modell (Unity Catalog) unterstützt.

Quelle: <https://docs.databricks.com/aws/en/getting-started/high-level-architecture>
Stand: 2026-08-06