

Databricks-Referenzarchitekturen (AWS)

Diese Seite stellt fertige Architektur-Blaupausen für den Betrieb von Databricks auf AWS vor. Sie zeigen, wie typische Datenflüsse – von der Quelle bis zur Auswertung – mit AWS-Diensten und Databricks-Komponenten zusammenspielen. Die Diagramme stehen als PDF im Format 11 x 17 Zoll (A3) zum Download bereit und sind hilfreich, um eigene Architektur-Entscheidungen an bewährten Mustern auszurichten.

Die zentrale Gesamtarchitektur

Im Zentrum steht ein großes Übersichtsdiagramm: "Reference architecture for the Databricks platform on AWS". Es zeigt das komplette Ökosystem und enthält unter anderem folgende AWS-Dienste:

- **Datenquellen und Integration:** Amazon Redshift (als Quelle für Lakehouse Federation)
- **Ingestion-Werkzeuge:** Amazon AppFlow, AWS Glue (Batch); AWS IoT Core, Amazon Kinesis, AWS DMS (Streaming)
- **Speicher:** Amazon S3 als Objektspeicher für Daten und KI-Assets
- **Operative Datenbanken:** Amazon RDS, Amazon DynamoDB
- **Analytics und BI:** Amazon QuickSight
- **KI-Integration:** Amazon Bedrock (Zugriff auf externe Sprachmodelle)

Die sieben "Spuren" der Architektur

Die Gesamtarchitektur lässt sich in sieben logische Bereiche ("Swim Lanes") unterteilen, die den Weg der Daten von der Quelle bis zur Analyse beschreiben:

1. Quellintegration (Source Integration)

- **ETL:** Halbstrukturierte, unstrukturierte und strukturierte Daten aus Sensoren, IoT-Geräten, Medien, Dateien, Logs, relationalen Datenbanken und Business-Anwendungen
- **Lakehouse Federation:** Direkter SQL-Zugriff auf relationale Datenbanken ohne separaten ETL-Prozess, gesteuert über Unity Catalog

- **Catalog Federation:** Einbindung von Hive-Metastore-Katalogen und AWS Glue über Unity Catalog

2. Ingestion (Batch und Streaming)

- **Lakeflow Connect:** Eingebaute Konnektoren für die Anbindung von Unternehmensanwendungen, mit serverlosem Compute und Governance über Pipelines
- **Auto Loader:** Lädt Dateien direkt aus Cloud-Speicher
- **Partner-Ingestion-Werkzeuge:** Quellenspezifische Adapter mit Ablage in Delta Lake
- **Structured Streaming:** Für Kafka, Sensoren, IoT und Change Data Capture (CDC – das Erfassen von Datenänderungen)

3. Speicher (Storage)

Daten werden nach dem Prinzip der Medallion-Architektur organisiert, entweder als Delta-Dateien/-Tabellen oder als Apache-Iceberg-Tabellen.

4. Transformation & Abfrage/Verarbeitung

- **Verarbeitungs-Engines:** Apache Spark und Photon
- **Pipeline-Framework:** Declarative Pipelines für zuverlässige, wartbare Datenverarbeitung
- **Workload-Unterstützung:** SQL-Warehouses für SQL-Abfragen, Cluster für SQL/Python/Scala
- **Data Science:** ML Runtimes, AutoML, MLflow für KI- und ML-Workflows

5. Serving (Bereitstellung)

- **Data Warehousing:** Databricks SQL, angetrieben von SQL-Warehouses (serverlos oder klassisch)
- **Machine Learning:** Model Serving (skalierbares, echtzeitfähiges Hosting in der Control Plane), Unity AI Gateway für Governance
- **Operative Datenbanken:** Lakebase (OLTP-Datenbank auf Postgres-Basis), externe operative Datenbanken
- **Datenzugriff:** Externe Systeme für die letzte Auslieferung von Datenprodukten

6. Zusammenarbeit (Collaboration)

- **OpenSharing:** Sicherer Partnerzugriff auf benötigte Daten
- **Databricks Marketplace:** Offener Marktplatz für den Austausch von Datenprodukten
- **Clean Rooms:** Datenschutzfreundliche Umgebungen, in denen mehrere Parteien gemeinsam mit sensiblen Daten arbeiten können, ohne die Rohdaten offenzulegen

7. Analyse

- **Business-Anwendungen:** Individuelle KI-Clients, die mit Model Serving verbunden sind, oder Anwendungen mit Zugriff auf operative Datenbanken
- **BI-Werkzeuge:** Analysten nutzen meist BI-Tools für den Zugriff auf das Data Warehouse
- **SQL-Entwickler:** Databricks SQL Editor für Abfragen und Dashboards
- **Visualisierung:** Native Dashboards für Dateneinblicke

Integrations- und Governance-Schicht

Quer über alle Bereiche hinweg gibt es eine Integrationsebene mit folgenden Fähigkeiten:

- Identity-Provider und Single Sign-On (SSO)
- Anbindung externer KI-Dienste (z. B. OpenAI, LangGraph, HuggingFace)
- REST-API- und Orchestrator-Anbindungen (z. B. Apache Airflow)
- Unity Catalog für die plattformweite Governance sowie die Anbindung externer Kataloge

Gemeinsame Fähigkeiten über alle Workloads hinweg

Daten- und KI-Governance

Unity Catalog fungiert als zentrales Governance-System für Daten und KI. Es verwaltet Zugriffsrichtlinien über Workspaces hinweg und unterstützt Tabellen, Volumes, Features und Modelle. Dazu gehören:

- Laufzeit-Datenherkunft (Data Lineage) – zeigt, woher Daten stammen und wohin sie fließen
- Datenqualitätsüberwachung mit Anomalieerkennung
- Vollständiges Daten-Profiling für alle Tabellen

Data Intelligence Engine

- KI-Assistenzfunktionen von Databricks, um Daten und KI in der Organisation besser nutzbar zu machen
- Genie Code: ein kontextbewusster KI-Assistent in Notebooks, im SQL-Editor und im Datei-Editor

Automatisierung & Orchestrierung

- **Lakeflow Jobs:** Orchestrierung von Datenverarbeitung, ML- und Analytics-Pipelines
- **Lakeflow Pipelines:** Deklarativer Aufbau von ETL-Prozessen
- Unterstützung für CI/CD und MLOps

Zwölf konkrete Anwendungsfall-Architekturen

Neben der Gesamtarchitektur bietet Databricks zwölf spezifischere Referenzarchitekturen für typische Anwendungsfälle, jeweils mit eigenem PDF zum Download:

1. **Lakeflow-Connect-Ingestion:** Eingebaute Konnektoren für Unternehmensanwendungen und Datenbanken, mit serverlosem Compute, Unity-Catalog-Governance und inkrementellem Lesen/Schreiben für effiziente, skalierbare, kostengünstige Datenaufnahme.
2. **Batch-Ingestion und ETL:** Quellenspezifische Adapter lesen Daten in Cloud-Speicher oder rufen Databricks direkt auf; Pipelines werden über Lakeflow Jobs orchestriert; Unity Catalog übernimmt Zugriffskontrolle, Audit und Data Lineage; Tabellen können in operative Datenbanken exportiert werden.
3. **Streaming und Change Data Capture (CDC):** Spark Structured Streaming liest aus Apache Kafka oder AWS Kinesis; Event-Queues speichern extrahierte CDC-Datensätze; der Auto Loader verarbeitet im Batch abgelegte Datensätze nach demselben Muster wie beim Batch-ETL.
4. **Machine Learning und KI (klassisch):** Umfasst moderne ML- und Deep-Learning-Bibliotheken, Feature Store und Model Registry (in Unity Catalog integriert), AutoML, MLflow-Integration, Governance von Data-Science-Assets über Unity Catalog, Orchestrierung über Lakeflow Jobs sowie MLOps für skalierbares Deployment von Modellen.

5. **Agenten-Anwendungen (Agent Applications):** MLOps-Fähigkeiten ermöglichen skalierbares, unternehmenstaugliches Deployment von Modellen über Model Serving.
6. **BI und SQL-Analytics:** Business-Analysten greifen über Databricks-Dashboards, den SQL-Editor oder BI-Tools (z. B. Tableau, Amazon QuickSight) auf Daten zu; angetrieben von Databricks SQL (serverlos oder klassisch); Unity Catalog ermöglicht Auffindbarkeit, Exploration, Data Lineage und Zugriffskontrolle.
7. **Business-Apps:** Mit Databricks Apps können Entwickler sichere Daten- und KI-Anwendungen direkt auf der Databricks-Plattform bauen und bereitstellen. Serverloses Hosting mit Anbindung wichtiger Dienste; bei Bedarf liefert Lakebase synchronisierte OLTP-Daten.
8. **Lakehouse Federation:** Externe SQL-Datenbanken (MySQL, Postgres, Redshift) werden ohne ETL eingebunden; externe Quellkataloge werden auf Unity Catalog abgebildet, inklusive feingranularer Zugriffskontrolle für KI-, DWH- und BI-Workloads.
9. **Catalog Federation:** Externe Hive-Metastores und Amazon Glue werden mit Unity Catalog verbunden; ermöglicht alle Workload-Typen, ohne Daten in den Objektspeicher zu kopieren; feingranulare Zugriffskontrolle über die Databricks-Plattform.
10. **Daten mit Drittanbieter-Tools teilen:** OpenSharing bietet unternehmenstauglichen Datenaustausch mit Dritten über abgesicherten Objektspeicher-Zugriff (gesteuert von Unity Catalog); bildet die technische Grundlage des Databricks Marketplace.
11. **Geteilte Daten von Databricks konsumieren:** Das Databricks-zu-Databricks-Protokoll von OpenSharing ermöglicht sicheren Datenaustausch über Konten- und Cloud-Grenzen hinweg für Workspace-Nutzer mit Unity-Catalog-Zugriff.
12. **Lakehouse Federation (Variante mit Schwerpunkt Föderation):** Ermöglicht die Integration externer SQL-Datenbanken, ohne dass Daten bewegt werden müssen.

Wichtige Begriffe auf einen Blick

Begriff	Bedeutung
Medallion-Architektur	Bewährtes Muster zur Organisation von Daten in Qualitätsstufen (Bronze/Silver/Gold)
Delta Lake	Primäres Datenformat von Databricks, neben Apache Iceberg
Unity Catalog	Einheitliches Governance-System für alle Datenobjekte

Photon Engine	Beschleunigte Verarbeitungstechnologie neben Apache Spark
Feature Store	Verwaltung von ML-Merkmalen (Features), in die Plattform integriert
Model Registry	Zentrale Versionierung und Governance von ML-Modellen
Serverless Compute	Von der Cloud verwaltete Rechenoption ohne eigene Cluster-Verwaltung
System Tables	Von Databricks bereitgestellter, analysierbarer Speicher operativer Account-Daten

Einordnung

Databricks betont, dass die Plattform offen ist und mit einem großen Ökosystem an Partner-Tools zusammenarbeitet. Die vorgestellten Referenzarchitekturen konzentrieren sich jedoch bewusst auf AWS-Dienste und Databricks-eigene Komponenten. Die gezeigten Cloud-Dienste veranschaulichen typische Konzepte, sind aber nicht als abschließende Liste zu verstehen.

Quelle: <https://docs.databricks.com/aws/en/lakehouse-architecture/reference>
Stand: 2026-08-06