

Die Medallion-Lakehouse-Architektur

Diese Seite erklärt die Medallion-Architektur – ein bewährtes Muster, um Daten in einem Lakehouse schrittweise von roher zu hochwertiger Qualität zu veredeln. Wer Datenpipelines in Databricks aufbaut, stößt fast zwangsläufig auf dieses Konzept, da es die Grundlage für viele Best-Practice-Empfehlungen bildet.

Grundidee

Die Medallion-Architektur ist ein Datendesign-Muster, das Daten in mehreren Schichten organisiert, die jeweils eine bestimmte Datenqualitätsstufe repräsentieren. Databricks beschreibt es so: Die Medallion-Architektur beschreibt eine Reihe von Datenschichten, die die Qualität der im Lakehouse gespeicherten Daten kennzeichnen. Das dreistufige System – **Bronze**, **Silver** und **Gold** – ermöglicht es, die Struktur und Qualität der Daten schrittweise und fortlaufend zu verbessern, während sie die einzelnen Stufen durchlaufen. Dieser mehrstufige Ansatz ("Multi-Hop") garantiert dabei durchgehend Atomarität, Konsistenz, Isolation und Dauerhaftigkeit (die bekannten ACID-Eigenschaften) bei allen Transformationen und Validierungen.

Die drei Schichten im Detail

Bronze-Schicht: Rohdaten

Die Bronze-Schicht ist der erste Einstiegspunkt für unverarbeitete Informationen.

- **Funktion:** Aufnahme von Rohdaten mit minimaler Verarbeitung
- **Datenzustand:** behält das ursprüngliche Format der Quellsysteme bei
- **Eigenschaften:**
 - Speichert Daten unverändert und ungeprüft
 - Wird inkrementell über die Zeit ergänzt (angefügt)
 - Bewahrt die vollständige Historie für Audits und erneute Verarbeitung
 - Dient als verbindliche Quelle und erhält die Datentreue

- Nimmt Daten aus Cloud-Speicher (S3, GCS, ADLS), Message-Systemen (Kafka, Kinesis) und angebundenen Fremdsystemen auf

Empfehlung zur Validierung: Databricks empfiehlt, die meisten Felder als `string`, `VARIANT` oder Binärformat zu speichern, um sich vor unerwarteten Schemaänderungen zu schützen. In dieser Schicht findet nur minimale Bereinigung statt, um Datenverlust durch Schemaabweichungen oder fehlerhafte Datensätze zu vermeiden.

Typische Nutzer: Data Engineers, Data-Operations-Teams sowie Compliance- und Audit-Personal.

Silver-Schicht: Validiert und bereinigt

Die Silver-Schicht wandelt die Bronze-Daten in validierte, strukturierte Formate um, die sich für weiterführende Analysen eignen.

Typische Datenqualitäts-Operationen:

- Durchsetzung und Weiterentwicklung von Schemas (Schema Enforcement und Evolution)
- Umgang mit fehlenden und Null-Werten
- Entfernen von Duplikaten (Deduplizierung)
- Auflösen von unsortiert oder verspätet eintreffenden Daten
- Qualitätsprüfungen und Typumwandlungen
- Verknüpfung (Join) verschiedener Datensätze

Eigenschaften: Die Silver-Schicht sollte immer mindestens eine validierte, nicht-aggregierte Darstellung jedes Datensatzes enthalten. Sie verbessert die Qualität durch Fehlerkorrektur, strukturiert Daten in gut nutzbare Formate und beginnt mit erster Datenmodellierung – etwa im Umgang mit verschachtelten oder halbstrukturierten Daten mittels `VARIANT`-Typen, JSON-Strings oder normalisierten Strukturen.

Empfehlung zur Ingestion: Databricks rät davon ab, direkt von der Quellen-Ingestion in die Silver-Schicht zu schreiben. Stattdessen sollten Daten aus Bronze oder Silver gelesen werden – die meisten Lesevorgänge aus Bronze erfolgen dabei als Streaming-Lesevorgänge, während Batch-Lesevorgänge kleinen Dimensionstabellen vorbehalten bleiben.

Typische Nutzer: Data Engineers, Data-Analysten (die verfeinerte, aber weiterhin detaillierte Datensätze benötigen) und Data Scientists, die Vorhersagemodelle entwickeln.

Gold-Schicht: Geschäftsfertig

Die Gold-Schicht liefert stark veredelte, aggregierte Daten, die für konkrete Geschäftsanwendungen optimiert sind.

- **Zweck:** versorgt Analysen, Dashboards, Machine-Learning-Anwendungen und Geschäftsberichte
- **Dateneigenschaften:**
 - Stark aggregiert und gefiltert nach Zeiträumen oder geografischen Regionen
 - Enthält semantisch bedeutungsvolle Datensätze, die auf konkrete Geschäftsfunktionen abgebildet sind
 - Oft gibt es mehrere Gold-Schichten für unterschiedliche Fachbereiche (HR, Finanzen, IT)
 - Optimiert für schnelle Abfragen und Dashboard-Performance

Modellierungsansatz: Nutzt dimensionale Modellierung, um Beziehungen herzustellen und Kennzahlen (Measures) passend zur Geschäftslogik zu definieren.

Performance-Optimierung: Große historische Datensätze bleiben in der Regel in der Silver-Schicht; die Gold-Schicht materialisiert nur häufig abgefragte Aggregate, um Kosten zu kontrollieren und die Abfragegeschwindigkeit zu erhöhen.

Typische Nutzer: Business-Analysten, BI-Entwickler, Data Scientists/ML-Engineers, Führungskräfte und operative Teams.

Beispiel: Datenfluss in einem Vertriebsszenario

Die Databricks-Dokumentation zeigt ein Beispiel aus dem Geschäftsbetrieb, wie Daten die Schichten durchlaufen:

Schicht	Beispielhafte Tabellen / Inhalte
ops.bronze	Rohe Ingestion aus Cloud-Speicher, Kafka und Salesforce, ohne Bereinigung oder Validierung
ops.silver	Kunden- und Transaktionsdaten werden bereinigt (Null-Werte entfernt, ungültige Datensätze isoliert) und zu <code>customer_transactions</code> zusammengeführt (für Data Scientists). Salesforce-Konten- und Opportunity-Datensätze werden zu <code>account_opportunities</code> verknüpft und um Kontoinformationen angereichert. Rohe Lead-Daten werden zu <code>leads_cleaned</code> transformiert.

ops.gold	customer_spending (durchschnittliche und gesamte Ausgaben pro Kunde), account_performance (tägliche Performance-Kennzahlen pro Konto), sales_pipeline_summary (Ende-zu-Ende-Informationen zur Vertriebs-Pipeline), business_summary (stark aggregierte Daten für die Führungsebene)
----------	--

Ingestion-Frequenz: Kosten gegen Aktualität abwägen

Organisationen müssen abwägen zwischen Kosten und Datenaktualität. Dafür gibt es drei typische Ansätze:

Ansatz	Kostenniveau	Aktualität (Latenz)	Umsetzung
Kontinuierlich inkrementell	Höher	Niedriger (aktueller)	Streaming-Tabellen mit dauerhaft laufender Pipeline
Getriggert inkrementell	Niedriger	Höher	Streaming-Tabellen, ausgelöst durch Zeitplan oder neue Dateien
Manueller Batch	Niedriger	Am höchsten	Batch-Lesevorgänge mit Partitions-Overwrite, ohne Structured Streaming

Vorteile und bewährte Praktiken

- **Datenqualität:** Schrittweise Validierung sorgt für Verlässlichkeit nachgelagerter Anwendungen
- **Trennung der Zuständigkeiten:** Unterschiedliche Nutzergruppen greifen auf die Schicht zu, die zu ihrem Bedarf passt
- **Nachvollziehbarkeit:** Vollständige Historie ermöglicht Compliance und Data Lineage
- **Skalierbarkeit:** Das mehrschichtige Design wächst mit zunehmender Datenkomplexität und Organisationsgröße mit
- **Kostenoptimierung:** Organisationen können Ingestion-Frequenz und Materialisierungsstrategie an ihre Anforderungen anpassen

Wichtige Einschränkung: Die Medallion-Architektur ist eine empfohlene Best Practice, aber keine zwingende Vorgabe. Organisationen können das Muster an ihre eigenen Bedürfnisse anpassen.

Quelle: <https://docs.databricks.com/aws/en/lakehouse/medallion>
Stand: 2026-08-06