

Data Discovery und Zusammenarbeit im Lakehouse

Diese Seite erklärt, wie Nutzer im Databricks-Lakehouse Daten finden (Data Discovery), sicher darauf zugreifen und gemeinsam mit anderen Teams daran arbeiten können. Das ist wichtig, weil ein Lakehouse nur dann seinen vollen Wert entfaltet, wenn Daten nicht nur zentral gespeichert, sondern auch leicht auffindbar und sicher teilbar sind.

Überblick

Databricks ermöglicht sichere, governte Zusammenarbeit über Daten-, Analytics- und KI-Workloads hinweg. Die Plattform nutzt dafür Unity Catalog sowie offene Protokolle wie OpenSharing, um Datenfindung, Datenaustausch und Datenanalyse zu erleichtern – bei gleichzeitiger Wahrung von Governance, Nachvollziehbarkeit (Auditierbarkeit) und Datenschutz.

Zentrale Werkzeuge und Funktionen

1. Unity Catalog

Hauptfunktion: Stellt ein einheitliches Berechtigungssystem über das gesamte Databricks-Ökosystem hinweg bereit.

Berechtigungsverwaltung:

- Administratoren können Berechtigungen für Kataloge, Datenbanken, Tabellen und Views an Benutzergruppen vergeben
- Berechtigungen und Metastores werden über Workspaces hinweg geteilt, was eine konsistente Zugriffskontrolle ermöglicht
- Berechtigungen werden einmalig gegen Gruppen vergeben, die aus dem Identity Provider synchronisiert werden
- Nutzer sehen nur die Daten, auf die sie berechtigt sind – unabhängig davon, in welchen Databricks-Workspace sie sich einloggen

Storage Credentials und External Locations:

- Administratoren können sichere Zugangsdaten (Storage Credentials) für die Cloud-Speicherinfrastruktur definieren
- Nutzer erhalten Berechtigungen, mit denen sie selbst externe Speicherorte (External Locations) gegenüber dem Cloud-Objektspeicher festlegen können
- Data Engineers können dadurch neue Workloads selbst einrichten (Self-Service), ohne erweiterte Berechtigungen im Cloud-Account zu benötigen

2. Catalog Explorer

Hauptfunktion: Eine Oberfläche zur Datenfindung, mit der Nutzer verfügbare Datenobjekte durchsuchen können.

Funktionsumfang:

- Zeigt Kataloge, Datenbanken, Tabellen und Views entsprechend den Berechtigungen des jeweiligen Nutzers an
- Zeigt Feldnamen, Datentypen sowie Kommentare zu Tabellen und Feldern
- Bietet Vorschauen auf Datenbeispiele (Data Samples)
- Enthält eine vollständige Tabellenhistorie, die Änderungen im Zeitverlauf nachvollziehbar macht
- Zeigt Data Lineage – also Herkunfts- und Abhängigkeitsbeziehungen (welche Daten flossen wo hinein, welche Ergebnisse entstanden daraus)
- Zeigt Storage Credentials und External Locations inklusive der zugehörigen Nutzerberechtigungen an

Nutzen: Nutzer finden relevante Datensätze und sehen dabei ausschließlich die Ressourcen, für die sie tatsächlich berechtigt sind.

3. Offene Protokolle (Open Protocols)

OpenSharing: Wird als ermöglichende Technologie für organisationsübergreifende Datenzusammenarbeit und Datenaustausch genannt – sie erlaubt es, Daten sicher mit externen Partnern zu teilen, ohne dass diese selbst eine Databricks-Umgebung benötigen.

Schnellerer Weg in die Produktion

Unterstützung mehrerer Programmiersprachen

Databricks unterstützt SQL, Python, Scala und R gleichermaßen. Dadurch können unterschiedliche Fachrollen – von Analysten bis zu Data Engineers – jeweils mit der ihnen vertrauten Sprache zu Analysen und Datenprodukten beitragen.

Vorteile für den Produktionsweg:

- SQL-Abfragen von Analysten lassen sich mit minimalen Anpassungen zu produktivem Data-Engineering-Code weiterentwickeln
- Notebooks unterstützen mehrere Programmiersprachen innerhalb desselben Dokuments
- Alle Rollen in der Organisation arbeiten mit denselben, identischen Datensätzen
- Es ist kein Abgleich von unterschiedlichen Feldnamen zwischen Teams nötig
- Dashboards bleiben über verschiedene gemeinsame Initiativen hinweg synchron

Sicheres Teilen von Code und Wissen

Code, Notebooks, Abfragen und Dashboards lassen sich sicher teilen. Alle Ressourcen nutzen dabei dieselbe skalierbare Cloud-Infrastruktur, und alle Arbeit bezieht sich auf dieselben kuratierten Datenquellen.

Warum das für den Praxisalltag wichtig ist

Ohne zentrale Data-Discovery-Werkzeuge verbringen Teams viel Zeit damit, herauszufinden, welche Daten überhaupt existieren, wer sie besitzt und ob sie vertrauenswürdig sind. Catalog Explorer und Unity Catalog lösen dieses Problem, indem sie Auffindbarkeit, Governance und Zusammenarbeit in einem einzigen, konsistenten System vereinen – über Sprachen, Teams und Workspaces hinweg.

Quelle: <https://docs.databricks.com/aws/en/lakehouse/collaboration>

Stand: 2026-08-06