

Compute in Databricks – Übersicht

Diese Seite gibt einen Überblick über alle Arten von Rechenressourcen ("Compute") in Databricks. "Compute" bezeichnet die Recheninfrastruktur, auf der Notebooks, Jobs, Pipelines und SQL-Abfragen ausgeführt werden. Da praktisch jede Arbeit in Databricks Compute benötigt, ist das Verständnis dieser Grundlagen essenziell für den weiteren Kurs.

Was ist Compute?

Mit Compute sind die Rechenressourcen gemeint, die Databricks bereitstellt, um Data-Engineering-, Data-Science- und Analytics-Workloads auszuführen. Man kann sich das wie einen "Motor" vorstellen: Code (z. B. ein Notebook oder eine SQL-Abfrage) wird geschrieben, aber ausgeführt wird er auf einem Compute-Cluster im Hintergrund. Databricks bietet dafür drei grundsätzlich unterschiedliche Ansätze an.

Die drei Compute-Kategorien

1. Serverless Compute

Bei Serverless Compute kümmert sich Databricks komplett um die Bereitstellung und Verwaltung der Recheninfrastruktur. Nutzer müssen keine Cluster konfigurieren – die Ressourcen werden automatisch je nach Workload skaliert und bei Bedarf sofort bereitgestellt. Es gibt Serverless-Varianten für:

- Notebooks (interaktives Arbeiten)
- Jobs (automatisierte Workflows)
- Pipelines (Lakeflow Declarative Pipelines, früher Delta Live Tables)

2. Classic Compute

Classic Compute sind Rechenressourcen, die Nutzer selbst erstellen, konfigurieren und verwalten. Diese Cluster laufen im Cloud-Konto des Kunden (z. B. AWS-Konto), nicht direkt bei Databricks verwaltet. Es gibt hier:

- **Standard Compute** für die gemeinsame Nutzung durch mehrere Personen

- **Dedicated Compute** für die exklusive Nutzung durch eine einzelne Person oder Gruppe
- **Instance Pools** zur Beschleunigung des Cluster-Starts und zur Kosteneinsparung

3. SQL Warehouses

SQL Warehouses sind speziell für SQL-Abfragen und Business-Intelligence-Workloads optimierte Rechenressourcen. Sie stehen sowohl als Serverless- als auch als Classic-Variante zur Verfügung und werden z. B. für Dashboards, BI-Tools (Power BI, Tableau) oder den SQL-Editor genutzt.

Vergleich der Compute-Typen

Typ	Wer verwaltet die Infrastruktur?	Typischer Einsatz
Serverless Compute	Databricks	Notebooks, Jobs, Pipelines ohne Infrastruktur-Aufwand
Classic Compute	Nutzer / Unternehmen (im eigenen Cloud-Konto)	Individuell konfigurierte Cluster für Data Engineering & Data Science
SQL Warehouses	Databricks (serverless) oder Nutzer (classic/pro)	SQL-Abfragen, BI-Dashboards

Zusätzliche Technologien

Photon ist eine von Databricks entwickelte, performante Abfrage-Engine, die SQL- und DataFrame-Workloads deutlich beschleunigt. Sie wird in einem eigenen Kapitel im Detail erklärt.

Lakeguard ist eine Sicherheitstechnologie, die dafür sorgt, dass sich mehrere Nutzer sicher eine gemeinsame Compute-Ressource teilen können, ohne dass sie sich gegenseitig Daten oder Code einsehen können. Auch dazu gibt es ein eigenes Kapitel.

Warum ist das wichtig?

Die Wahl der richtigen Compute-Art hat direkten Einfluss auf Kosten, Geschwindigkeit und Verwaltungsaufwand. Serverless Compute ist meist die einfachste Wahl (kein Verwaltungsaufwand), während Classic Compute mehr Kontrolle, aber auch mehr Konfigurationsaufwand bedeutet. Die folgenden Kapitel gehen im Detail auf jede Variante ein.

