

Serverless Compute für Notebooks

Diese Seite erklärt, wie Serverless Compute für Notebooks funktioniert: eine automatisch verwaltete Rechenressource, bei der Nutzer keine Cluster mehr selbst konfigurieren müssen. Das ist besonders für Einsteiger relevant, weil es das Arbeiten mit Notebooks stark vereinfacht.

Was ist Serverless Compute für Notebooks?

Serverless Compute erlaubt es, Notebook-Code auszuführen, ohne vorher einen Cluster zu erstellen oder zu verwalten. Databricks stellt die benötigten Ressourcen automatisch bereit und skaliert sie passend zur Auslastung. Man muss sich also nicht mehr um Instanztypen, Cluster-Größen oder Autoscaling-Einstellungen kümmern.

Voraussetzungen

Der Workspace muss für Unity Catalog aktiviert sein (Unity Catalog ist das zentrale Governance- und Metadatensystem von Databricks für Daten und KI-Assets).

Aktivieren und Nutzen

Wenn Serverless Compute im Workspace aktiviert ist, haben automatisch alle Nutzer Zugriff darauf – zusätzliche Berechtigungen sind nicht nötig. Um ein Notebook mit Serverless Compute zu verbinden, wählt man im Compute-Dropdown-Menü einfach "Serverless" aus. Bei neuen Notebooks, bei denen noch keine Ressource ausgewählt wurde, wird beim ersten Ausführen von Code automatisch Serverless Compute verwendet.

Performance-Einblicke ("Query Insights")

Nach der Ausführung einer Notebook-Zelle kann man über den Link "See performance" detaillierte Leistungsmetriken einsehen. Diese Funktion deckt sowohl SQL- als auch Python-Abfragen ab und zeigt Kennzahlen zur Spark-Ausführung. Man kann in einzelne Spark-Anweisungen hineinschauen und sich ein "Query Profile" (eine visuelle Darstellung der Ausführung) ansehen. Alle Abfragen werden zudem in der Query-History-Seite des Workspace protokolliert.

Einschränkungen bei den Query Insights

- Metriken werden zwar live während der Ausführung aktualisiert, das vollständige Profil erscheint aber erst nach Abschluss der Abfrage.
- Nur die Status RUNNING, CANCELED, FAILED und FINISHED werden erfasst.
- Laufende Abfragen können nicht direkt aus der Query History heraus abgebrochen werden (das Abbrechen erfolgt im Notebook oder Job selbst).
- Detaillierte Metriken, das Herunterladen von Profilen und der Zugriff auf die klassische Spark-UI sind nicht verfügbar.
- Der angezeigte Abfragetext zeigt nur die letzte ausgeführte Zeile – bei mehrzeiligen Anweisungen kann davorstehender Code fehlen.

Schutz vor unerwarteten Kosten: Timeout-Konfiguration

Damit Kosten nicht unkontrolliert steigen, gibt es standardmäßig ein Ausführungs-Timeout von 2,5 Stunden (9.000 Sekunden). Abfragen, die dieses Limit überschreiten, werden automatisch abgebrochen.

Workspace-Administratoren können diesen Standardwert über die Workspace-Einstellungen anpassen: *Compute* > *Serverless interactive* > *Serverless interactive execution timeout*. Änderungen benötigen ungefähr fünf Minuten, bis sie wirksam werden.

In einzelnen Notebooks lässt sich der Standardwert auch individuell überschreiben, indem man im Code die Einstellung `spark.databricks.execution.timeout` setzt. Die notebook-spezifische Einstellung hat dabei Vorrang vor der Workspace-weiten Einstellung.

Kosten

Genaue Preisangaben findet man auf der Databricks-Preisseite für Data-Science- und Machine-Learning-Produkte. Grundsätzlich gilt: Man zahlt nur für tatsächlich genutzte Rechenzeit, da keine dauerhaft laufenden Cluster mehr nötig sind.

Verwandte Themen

Neben Serverless Compute für Notebooks gibt es analog auch Serverless Compute für Jobs (automatisierte Workflows) mit eigenen Performance-Monitoring-Funktionen – siehe das entsprechende Kapitel dieses Kurses.

