

Serverless Compute für Jobs

Diese Seite beschreibt, wie automatisierte Workflows ("Jobs") in Databricks mit Serverless Compute ausgeführt werden können, ohne dass man selbst Infrastruktur einrichten muss. Das ist besonders praktisch für produktive, wiederkehrende Datenpipelines.

Was ist Serverless Compute für Jobs?

Serverless Compute für Jobs (Lakeflow Jobs) ermöglicht es, einen Job auszuführen, "ohne Infrastruktur konfigurieren und bereitstellen zu müssen". Databricks übernimmt die komplette Verwaltung der Rechenressourcen automatisch.

Wie es funktioniert

Das System optimiert die Infrastruktur automatisch – etwa Instanztypen, Arbeitsspeicher und die verwendeten Verarbeitungs-Engines – um die beste Leistung für den jeweiligen Workload zu erzielen. Autoscaling und die Photon-Engine sind automatisch aktiviert. Zudem werden die verwendeten Databricks-Runtime-Versionen automatisch aktualisiert, um von Plattform-Verbesserungen zu profitieren, während gleichzeitig die Stabilität der Jobs erhalten bleibt.

Voraussetzungen

- Unity Catalog muss im Workspace aktiviert sein.
- Workloads müssen den "Standard Access Mode" unterstützen (den Serverless Compute verwendet).
- Es werden keine speziellen Cluster-Erstellungsrechte benötigt – alle Nutzer im Workspace können diese Funktion nutzen.

Unterstützte Task-Typen

Serverless Compute unterstützt fünf Task-Typen: Notebook, Python-Skript, dbt, Python Wheel und JAR (JAR-Unterstützung befindet sich aktuell in der Public Preview, also einer öffentlichen Testphase). Beim Erstellen eines neuen Jobs wird Serverless Compute standardmäßig als Compute-Typ ausgewählt.

Konfigurationsmöglichkeiten

Performance-Modus

Modus	Eigenschaften
Standard	Geringerer Ressourcenverbrauch, günstiger; Startzeit von ca. 4–6 Minuten
Performance optimized	Schnellerer Start und schnellere Ausführung für zeitkritische Workloads

Beide Modi nutzen dieselbe Abrechnungseinheit (SKU), unterscheiden sich aber im Verbrauch an DBUs (Databricks Units, der Maßeinheit für die Abrechnung).

High Memory (Public Preview)

Nur für Notebook-Tasks verfügbar, konfigurierbar über den Environment-Bereich in der Benutzeroberfläche.

Spark-Parameter

Nur bestimmte Spark-Konfigurationsparameter sind erlaubt; diese müssen auf Sitzungsebene innerhalb der Notebooks gesetzt werden, die im selben Job enthalten sind.

Serverless Usage Policies (Public Preview)

Organisationen können benutzerdefinierte Tags für die Kostenzuordnung bei der Serverless-Nutzung anlegen. Diese Policies müssen manuell pro Job ausgewählt werden; bestehende Jobs werden nicht automatisch aktualisiert, wenn neue Policies definiert werden.

Automatische Wiederholung fehlgeschlagener Tasks

Standardmäßig aktiviert die Serverless-Auto-Optimierung automatische Wiederholungsversuche für fehlgeschlagene Tasks. Über den Dialog "Retry Policy" lässt sich dies deaktivieren – wichtig für Workloads, die nicht mehrfach ausgeführt werden dürfen ("at most once"-Ausführung, also nicht idempotente Jobs).

Nutzung und Umstellung

Neue Jobs: Bei unterstützten Task-Typen wird Serverless Compute automatisch ausgewählt.

Bestehende Jobs umstellen: Im Job-Detailbereich unter "Compute" auf "Swap" klicken, "New" auswählen, Einstellungen anpassen und bestätigen.

Direkt aus Notebooks planen: Über die Notebook-Planungsfunktion lassen sich geplante Jobs direkt aus einem Notebook erstellen.

Unterschied zu Classic Compute

Im Gegensatz zum klassischen, Cluster-basierten Ansatz entfällt der gesamte Aufwand für die Bereitstellung von Infrastruktur. Zu beachten ist jedoch: Bei Jobs mit hohem Speicherbedarf oder vielen Tasks können sich die Startzeiten verlängern.

Kostenüberwachung

Die Kosten lassen sich über System-Tabellen zur abrechenbaren Nutzung überwachen, die Nutzer- und Workload-Attribute zu den Serverless-Kosten enthalten. Aktuelle Preise finden sich auf der Workflows-Preisseite.

Ausgehender Netzwerkverkehr

Für die Steuerung ausgehender Verbindungen gibt es eine sogenannte "Serverless Egress Control", die über Netzwerk-Policies verwaltet wird.

Einsicht in Abfragen

Über die Timeline-Funktion in der Jobs-Oberfläche lassen sich detaillierte Laufzeitinformationen einsehen, einschließlich einzelner Task-Metriken, Abfrage-Statements und Laufzeiten. Query-Profile liefern Details zur Ausführung, und die Query History lässt sich nach der Task-Run-ID filtern.

Einschränkungen

Für detaillierte Einschränkungen verweist die Dokumentation auf ein eigenes Kapitel zu den Limitierungen von Serverless Compute (siehe entsprechendes Kapitel in diesem Kurs).

Quelle: <https://docs.databricks.com/aws/en/jobs/run-serverless-jobs> · Stand: 2026-08-06