

Was ist Photon?

Photon ist die von Databricks selbst entwickelte Ausführungs-Engine, die Abfragen erheblich beschleunigt. Da Photon in vielen Compute-Typen automatisch aktiv ist, hilft ein Grundverständnis dabei, Performance-Verhalten und Kosten besser einzuschätzen.

Was ist Photon?

Photon ist die native, vektorisierte Abfrage-Engine von Databricks. Sie beschleunigt SQL-Operationen, DataFrame-API-Aufrufe, ETL-Pipelines und zustandslose ("stateless") Streaming-Workloads. Statt Daten Zeile für Zeile zu verarbeiten, verarbeitet Photon Daten in spaltenweisen ("kolumnaren") Batches – das bringt erhebliche Performance-Vorteile, während die volle Kompatibilität mit bestehenden Apache-Spark-APIs erhalten bleibt.

Wie funktioniert Photon?

Photon ersetzt die JVM-basierte Ausführungsschicht von Spark SQL durch eine native C++-Laufzeitumgebung, während der Catalyst-Optimizer von Apache Spark weiterhin für die Abfrageplanung zuständig bleibt. Die Engine verarbeitet Daten "in Batches von jeweils tausenden Zeilen", wodurch moderne CPUs SIMD-Befehle (Single Instruction, Multiple Data – parallele Verarbeitung mehrerer Datenwerte mit einem Befehl) effizient nutzen können. Durch den Verzicht auf Garbage-Collection-Pausen, JIT-Aufwärmzeiten (Just-In-Time-Kompilierung) und zusätzlichen Speicher-Overhead maximiert Photon die CPU-Pipeline-Effizienz sowie die Speicherbandbreite durch cache-freundliche, sequenzielle Lesezugriffe.

Wichtige Performance-Vorteile

- **Schnellere Abfragen:** Laut TPC-DS-Benchmarks bis zu 5-fach besseres Preis-Leistungs-Verhältnis im Vergleich zu konkurrierenden Cloud-Data-Warehouses.
- **Optimierte Joins und Shuffles:** Ersetzt Sort-Merge-Joins durch performante Hash-Joins und neu entwickelte, spaltenweise Shuffle-Operationen.
- **Schreibperformance:** Ein nativer Parquet-Writer beschleunigt das Schreiben von Delta Lake, Apache Iceberg und Parquet-Dateien – besonders deutlich bei breiten Tabellen mit vielen Spalten.

- **Effizientes Scannen:** Nutzt Filter-Pushdown, Dictionary-Pruning und das Überspringen nicht relevanter Zeilengruppen (Row-Group-Skipping).
- **Disk-Caching und Nebenläufigkeit:** Schnellerer wiederholter Zugriff und besserer Durchsatz bei interaktiven BI-Workloads.

Aktivierung und Kompatibilität

Photon ist automatisch aktiviert auf Serverless Compute, SQL Warehouses und Serverless-Lakeflow-Pipelines. Bei Classic Compute können Administratoren die Option "Use Photon Acceleration" beim Erstellen der Ressource aktivieren oder deaktivieren, alternativ über den API-Parameter

`runtime_engine: PHOTON`. Die Aktivierung erfordert keinerlei Codeänderungen.

Unterstützte Workloads

Photon beschleunigt unter anderem:

- SQL-Analysen und BI-Dashboards
- ETL- und Batch-Data-Engineering-Operationen
- Lakeflow-Pipelines
- Zustandsloses Streaming (Delta- und Parquet-Ziele mit Kafka- oder Kinesis-Quellen)
- Feature Engineering für KI/ML und GraphFrames-Operationen

Technische Unterstützung und Fallback-Verhalten

Photon unterstützt eine breite Palette an Operatoren (Scans, Aggregationen, Joins, Fensterfunktionen), Ausdrücken (Vergleiche, Arithmetik, String- und Datums-/Zeitstempeloperationen) und Datentypen (numerische, String- und komplexe Typen inklusive Geometrie und Geografie). Trifft Photon auf nicht unterstützte Operationen, fällt es transparent auf die klassische Spark-Laufzeit zurück – die Korrektheit der Abfrage bleibt dabei stets erhalten.

Einschränkungen

- Keine Unterstützung für benutzerdefinierte Funktionen (UDFs), RDD-APIs oder Dataset-APIs.
- Zustandsbehaftetes ("stateful") Streaming wird nicht unterstützt.
- Bei Abfragen, die ohnehin in unter zwei Sekunden abgeschlossen sind, ist die Verbesserung nur minimal.

- Bei Graviton-basierten Instanzen mit Photon sind Databricks Container Services für Dedicated Compute und SQL Warehouses ausgeschlossen.

Quelle: <https://docs.databricks.com/aws/en/compute/photon> · Stand: 2026-08-06