

Was ist Lakeguard?

Lakeguard ist die Sicherheitstechnologie, die es mehreren Nutzern erlaubt, sich sicher eine gemeinsame Compute-Ressource zu teilen. Sie ist die technische Grundlage dafür, dass Standard Compute überhaupt sicher mehrbenutzerfähig sein kann – ein wichtiges Konzept, um Datensicherheit in Databricks zu verstehen.

Was ist Lakeguard?

Lakeguard ist "eine Reihe von Technologien in Databricks, die Code-Isolation und Datenfilterung durchsetzen" und dadurch sichere gemeinsame Nutzung von Ressourcen ermöglichen. Mehrere Nutzer können so dieselbe Compute-Infrastruktur nutzen, während strikte Sicherheitsgrenzen und feingranulare Zugriffskontrollen eingehalten werden.

Sicherheits- und Isolationsmechanismen

Lakeguard bietet zwei zentrale Isolationsmechanismen:

Isolation auf Spark-Client-Ebene

Das System nutzt Spark Connect, um Client-Anwendungen vom Spark-Driver zu trennen – beide teilen sich damit keine gemeinsame JVM (Java Virtual Machine) oder gemeinsamen Classpath mehr. Diese architektonische Änderung verhindert unautorisierten Datenzugriff und beseitigt das Risiko des "Overfetchings" (also des versehentlichen Ladens zu vieler Daten), wenn Zeilen- oder Spaltenfilter angewendet werden. Zusätzlich läuft jeder Client in seiner eigenen, containerisierten Sandbox-Umgebung, wodurch klare Sicherheitsgrenzen zwischen einzelnen Nutzern und der zugrunde liegenden Maschine entstehen.

Isolation von UDFs

Benutzerdefinierte Funktionen (UDFs) erhalten eigene, abgeschottete Ausführungsumgebungen auf den Spark-Executors. Das System isoliert dabei auch den ausgehenden Netzwerkverkehr von UDFs und repliziert die Client-Umgebung in die UDF-Sandbox, um sowohl Sicherheit als auch Zugriff auf benötigte Bibliotheken zu gewährleisten.

Anwendung auf verschiedene Compute-Typen

Compute-Typ	Isolationsgrad
Standard Classic Compute, Serverless Compute, SQL Warehouses	Volle Isolation über Lakeguard, inklusive nativer feingranularer Zugriffskontrolle mit Zeilenfiltern und Spaltenmaskierung
Dedicated Compute	Nutzt die klassische Spark-Architektur, bei der Nutzer-Code nicht von der Engine isoliert ist. Für feingranulare Zugriffskontrollen wird die Datenfilterung an workspace-eigenes Serverless Compute delegiert (dafür muss Serverless Compute aktiviert sein).

Vorteile

Durch diese Architektur lässt sich Infrastruktur kosteneffizient gemeinsam nutzen, ohne bei der Sicherheit Kompromisse einzugehen. Organisationen können so ihre Infrastruktur konsolidieren und gleichzeitig strikte Nutzergrenzen sowie Datenzugriffskontrollen einhalten.

Quelle: <https://docs.databricks.com/aws/en/compute/lakeguard> · Stand: 2026-08-06