

Databricks Notebooks – Übersicht

Diese Seite gibt einen Überblick über Databricks-Notebooks: das zentrale Werkzeug, mit dem in Databricks Daten analysiert, Code geschrieben und Machine-Learning-Modelle entwickelt werden. Sie dient als Landkarte für alle folgenden Themen dieses Kursbereichs.

Was ist ein Databricks-Notebook?

Ein Notebook ist ein interaktives Dokument, in dem Code, Text (in Markdown) und Ergebnisse (Tabellen, Diagramme) gemeinsam in einzelnen "Zellen" angeordnet sind. Man schreibt Code in eine Zelle, führt sie aus und sieht das Ergebnis direkt darunter. Notebooks in Databricks bieten zusätzlich:

- **Echtzeit-Zusammenarbeit:** Mehrere Personen können gleichzeitig im selben Notebook arbeiten, ähnlich wie bei einem gemeinsam bearbeiteten Google-Dokument.
- **Automatische Versionierung:** Änderungen werden automatisch nachverfolgt, sodass frühere Stände wiederhergestellt werden können.
- **Eingebaute Visualisierungen:** Aus Abfrageergebnissen lassen sich direkt Diagramme erzeugen, ohne zusätzliche Bibliotheken einrichten zu müssen.

Unterstützte Programmiersprachen

Notebooks unterstützen vier Sprachen, die auch innerhalb desselben Notebooks gemischt werden können:

- **Python** – die am häufigsten verwendete Sprache für Data Science und Machine Learning
- **SQL** – zum Abfragen von Tabellen
- **Scala** – die native Sprache von Apache Spark
- **R** – verbreitet in Statistik und Datenanalyse

Themenbereiche dieses Kurses

1. Einstieg mit Tutorials

Praxisnahe Anleitungen für typische Anwendungsfälle:

- **Daten abfragen und visualisieren:** Beispieldaten aus Unity Catalog (der zentralen Datenverwaltung von Databricks) abfragen und als Diagramm darstellen.
- **CSV-Dateien importieren und visualisieren:** Eigene CSV-Dateien hochladen, in eine Tabelle umwandeln und visualisieren.
- **Explorative Datenanalyse (EDA):** Systematisches Erkunden eines Datensatzes mit Python.
- **Klassische ML-Modelle Ende-zu-Ende:** Kompletter Machine-Learning-Workflow von Datenvorbereitung bis Modell-Tracking mit MLflow.

2. Notebooks entwickeln und ausführen

- **Grundlagen der Bearbeitung:** Zellen, Tastenkürzel, grundlegende Bedienung.
- **Code schreiben:** Mehrsprachige Entwicklung mit Syntaxhervorhebung und Autovervollständigung.
- **Notebooks ausführen:** Einzelne Zellen oder das gesamte Notebook ausführen, verschiedene Rechenressourcen (Compute) nutzen.
- **Data Science Agent:** Ein KI-Assistent (Genie Code im Agent-Modus), der komplette Analyse-Workflows aus einem einzigen Prompt erstellen kann.

3. Zusammenarbeit und Teilen

- **Import/Export:** Notebooks in verschiedenen Formaten austauschen.
- **Echtzeit-Zusammenarbeit:** Gemeinsames Bearbeiten, Kommentare, Berechtigungen.
- **Dashboards:** Aus Notebook-Ergebnissen interaktive Dashboards für das ganze Team erstellen.

4. Debugging und Code-Qualität

- **Genie Code Assistant:** KI-gestützte Code-Vorschläge, Fehlerdiagnose und Erklärungen.
- **Interaktiver Debugger:** Schrittweises Durchgehen von Python-Code zur Fehlersuche.
- **Unit-Tests:** Strategien, um Code zuverlässig zu testen.

5. Weitere wichtige Funktionen

- **Widgets:** Interaktive Eingabeparameter für Notebooks.
- **Ausgaben verwalten:** Arbeiten mit Ergebnistabellen, Filtern, Herunterladen von Daten.
- **Notebook-Workflows:** Notebooks orchestrieren und Code modularisieren.

- **Best Practices:** Empfehlungen für professionelle, wartbare Notebook-Entwicklung.

Databricks basiert auf Apache Spark, einer Open-Source-Engine für die verteilte Verarbeitung großer Datenmengen. Alle Notebook-Funktionen sind auf allen unterstützten Cloud-Plattformen (AWS, Azure, GCP, SAP) grundsätzlich gleich nutzbar.

Quelle: <https://docs.databricks.com/aws/en/notebooks/>

Stand: 2026-08-06