

Tutorial: Daten abfragen und visualisieren

Dieses Einsteiger-Tutorial zeigt, wie man in einem Notebook Beispieldaten abfragt und daraus ein Diagramm erstellt. Es ist der klassische erste Schritt, um sich mit der Notebook-Oberfläche vertraut zu machen.

Voraussetzungen

- Der Workspace muss **Unity Catalog** aktiviert haben. Unity Catalog ist die zentrale Verwaltungsschicht von Databricks für Daten, Zugriffsrechte und Metadaten.
- Man benötigt Berechtigung, eine Rechenressource (Compute, z. B. einen Cluster) zu nutzen oder selbst zu erstellen – gegebenenfalls muss ein Administrator dies freigeben.

Schritt 1: Neues Notebook erstellen

Im linken Seitenmenü auf **Neu** klicken und dann **Notebook** auswählen. Es öffnet sich ein leeres Notebook.

Schritt 2: Beispieldaten abfragen

Abgefragt wird die mitgelieferte Beispieldaten-Tabelle `samples.nyctaxi.trips` (Taxifahrten in New York). Je nach gewählter Sprache sieht der Code so aus:

- **SQL:** `SELECT * FROM samples.nyctaxi.trips`
- **Python:** `display(spark.read.table("samples.nyctaxi.trips"))`
- **Scala:** identischer Aufruf wie Python, nur mit Scala-Syntax
- **R:** zunächst `library(SparkR)` laden, dann `display(sql("SELECT * FROM samples.nyctaxi.trips"))`

Die Funktion `display()` ist eine Databricks-Besonderheit: Sie stellt Ergebnisse als interaktive, formatierte Tabelle dar. Eine Zelle wird mit **Shift+Enter** ausgeführt, wodurch anschließend automatisch zur nächsten Zelle gesprungen wird.

Schritt 3: Visualisierung erstellen

Aus der Ergebnistabelle lässt sich direkt ein Diagramm erzeugen:

1. Auf das **+**-Symbol neben dem Reiter **Table** klicken.
2. **Visualization** auswählen.
3. Im Diagramm-Editor folgende Einstellungen wählen:
 - Diagrammtyp: *Bar* (Balkendiagramm)
 - X-Spalte: `fare_amount` (Fahrpreis)
 - Y-Spalte: `trip_distance` (Fahrstrecke)
 - Aggregation: *Average* (Durchschnitt)
 - Gruppierung nach: `pickup_zip` (Postleitzahl der Abholung)
4. Auf **Save** klicken.

Das Ergebnis ist ein Balkendiagramm, das die durchschnittliche Fahrstrecke im Verhältnis zum Fahrpreis, gruppiert nach Abhol-Postleitzahl, zeigt.

Wichtige Konzepte

Begriff	Bedeutung
Unity Catalog	Zentrale Datenverwaltung mit Zugriffskontrolle für Tabellen, Dateien und mehr
display()	Databricks-Funktion zur formatierten, interaktiven Ausgabe von Ergebnissen
Aggregation	Zusammenfassung mehrerer Werte, z. B. durch Mittelwertbildung
Gruppierung	Aufteilung der Ergebnisse in Kategorien für den Vergleich

Weiterführende Themen

Passend anschließende Tutorials behandeln den CSV-Import, Apache-Spark-DataFrames, weitere Datenanbindungen sowie explorative Datenanalyse.

Quelle: <https://docs.databricks.com/aws/en/getting-started/quick-start>
Stand: 2026-08-06