

Tutorial: CSV-Dateien importieren und visualisieren

Dieses Tutorial zeigt den kompletten Weg von einer eigenen CSV-Datei bis zu einer gespeicherten, visualisierten Tabelle in Databricks – ein sehr häufiger Einstiegs-Workflow für eigene Daten.

Voraussetzungen

- Unity Catalog muss aktiviert sein (bei Free Edition und Testversionen standardmäßig der Fall).
- Benötigte Rechte: **WRITE VOLUME** auf einem Volume, **USE SCHEMA** auf dem Schema, **USE CATALOG** auf dem Katalog. Ein **Volume** ist ein Speicherort innerhalb von Unity Catalog für beliebige Dateien.
- Berechtigung zur Nutzung/Erstellung von Compute-Ressourcen.
- Bei der kostenlosen Free Edition: nur Python wird unterstützt (kein R/Scala), und der Upload muss über die Benutzeroberfläche erfolgen, da der Internetzugriff eingeschränkt ist.

Ablauf

Schritt 1: Notebook erstellen

Über **Neu** → **Notebook** im Seitenmenü ein leeres Notebook anlegen.

Schritt 2: Variablen definieren

Zu Beginn werden Katalog, Schema, Volume-Name sowie die Quelle der Beispieldaten (ein öffentlicher CSV-Datensatz mit Vornamen von Neugeborenen aus dem US-Bundesstaat New York) als Variablen festgelegt, zum Beispiel in Python:

```
catalog = "<catalog_name>"
schema = "<schema_name>"
volume = "<volume_name>"
download_url = "https://health.data.ny.gov/api/views/jxy9-yhdk/rows.csv"
```

```
file_name = "baby_names.csv"
table_name = "baby_names"
path_volume = "/Volumes/" + catalog + "/" + schema + "/" + volume
```

In Scala werden dieselben Werte mit `val` und String-Interpolation gesetzt, in R mit `<-` und `paste()`. Katalog- und Schema-Namen findet man über das Katalog-Symbol im Seitenmenü. Falls kein Volume existiert, kann eines per SQL angelegt werden: `CREATE VOLUME IF NOT EXISTS <catalog>.<schema>.my_volume`.

Schritt 3: CSV-Datei importieren

Es gibt zwei Wege:

- **Variante A – Hochladen über die Oberfläche** (verpflichtend bei Free Edition): Die CSV-Datei im Browser herunterladen, in `baby_names.csv` umbenennen, dann in Databricks über **Neu → Add or upload data → Upload files to a volume** in das gewünschte Volume hochladen.
- **Variante B – Direkt per Code herunterladen** (wenn Internetzugriff möglich ist), z. B. in Python: `dbutils.fs.cp(f"{download_url}", f"{path_volume}/{file_name}")`.
`dbutils.fs` ist ein Databricks-Dienstprogramm für Dateisystem-Operationen.

Schritt 4: CSV in ein DataFrame laden

Mit Apache Spark wird die Datei in ein **DataFrame** geladen (eine tabellenartige Datenstruktur, die verteilt verarbeitet werden kann):

```
df = spark.read.csv(f"{path_volume}/{file_name}", header=True, inferSchema=True, sep=",")
```

`header=True` bedeutet, dass die erste Zeile Spaltennamen enthält, `inferSchema=True` lässt Spark die Datentypen automatisch erkennen. Neben CSV werden auch viele andere Dateiformate unterstützt.

Schritt 5: Daten visualisieren

`display(df)` zeigt die Tabelle interaktiv an. Anschließend über **+ → Visualization** ein Diagramm erstellen: Diagrammtyp *Word Cloud* (Wortwolke), Spalte `First Name`, Häufigkeits-Limit 35, dann **Save**. Das Ergebnis ist eine Wortwolke der häufigsten Vornamen.

Schritt 6: DataFrame als Tabelle speichern

Vor dem Speichern müssen Sonderzeichen aus Spaltennamen entfernt werden (Leerzeichen sind in Spaltennamen nicht erlaubt):

```
df = df.withColumnRenamed("First Name", "First_Name")
df.write.mode("overwrite").saveAsTable(f"{path_table}.{table_name}")
```

`mode("overwrite")` überschreibt eine eventuell vorhandene gleichnamige Tabelle. Zum Speichern ist die Berechtigung `CREATE` auf Katalog und Schema nötig. Über das Katalog-Symbol im Seitenmenü lässt sich die neue Tabelle anschließend prüfen (Schema-Übersicht und Stichprobendaten).

Vorgefertigte Beispiel-Notebooks

Databricks stellt für Python, Scala und R jeweils ein fertiges Beispiel-Notebook mit allen Schritten bereit, das direkt geöffnet oder importiert werden kann.

Wichtige Fakten

- Free-Edition- und Serverless-Umgebungen haben eingeschränkten oder keinen ausgehenden Internetzugriff.
- Spaltennamen dürfen keine Sonderzeichen (inkl. Leerzeichen) enthalten, bevor eine Tabelle gespeichert wird.
- Apache Spark ist eine eingetragene Marke der Apache Software Foundation.

Weiterführende Tutorials

Empfohlene nächste Schritte: explorative Datenanalyse, Aufbau einer ETL-Pipeline mit Lakeflow, Laden und Transformieren von Daten mit Spark-DataFrames.

Quelle: <https://docs.databricks.com/aws/en/getting-started/import-visualize-data>
Stand: 2026-08-06