

Klassische ML-Modelle Ende-zu-Ende mit MLflow

Diese Seite verlinkt auf vollständige Beispiel-Notebooks, die den kompletten Weg vom Rohdatensatz bis zum eingesetzten Machine-Learning-Modell zeigen – inklusive Tracking und Verwaltung mit MLflow. Sie ist eher ein Einstiegspunkt zu fertigen Notebooks als eine Schritt-für-Schritt-Anleitung auf der Seite selbst.

Verfügbare Beispiel-Notebooks

Je nach Workspace-Konfiguration gibt es drei passende Varianten:

Notebook	Wann verwenden
XGBoost mit MLflow 3 (Unity Catalog)	Workspace mit Unity Catalog und der neuesten MLflow-3-Version
XGBoost mit MLflow 2.x (Unity Catalog)	Workspace mit Unity Catalog, aber älterer MLflow-Version
scikit-learn mit MLflow	Workspace ohne Unity Catalog

Was der Workflow abdeckt

- **Daten laden:** Import des Trainingsdatensatzes in die Databricks-Umgebung.
- **Daten visualisieren:** Erste Sichtung und grafische Aufbereitung der Merkmale.
- **Hyperparameter-Optimierung:** Parallele Suche nach den besten Modell-Einstellungen (z. B. Baumtiefe, Lernrate bei XGBoost).
- **MLflow-Integration:** Nachverfolgung von Experimenten (Tracking), Registrierung von Modellen in einer zentralen Modellablage (Model Registry) und Verwaltung des Modell-Lebenszyklus.
- **Inferenz:** Anwendung des registrierten Modells auf neue Daten mithilfe einer Spark-UDF (einer benutzerdefinierten Funktion, die das Modell verteilt auf große Datenmengen anwendet).

Wichtige Begriffe erklärt

- **MLflow Tracking:** Protokolliert automatisch Parameter, Kennzahlen (Metriken) und Artefakte jedes Trainingslaufs, sodass Experimente vergleichbar bleiben.
- **Model Registry:** Zentrale Ablage, in der trainierte Modellversionen gespeichert, versioniert und für die Produktion freigegeben werden.
- **Autologging:** Automatische Protokollierung von Modellparametern und Metriken, ohne dass man das manuell programmieren muss.
- **Spark-UDF:** Eine Funktion, die es erlaubt, ein trainiertes Modell auf große, verteilte Datensätze anzuwenden.

Nutzung

Die Notebooks lassen sich vollständig durchlaufen oder nur in Teilen für eigene Projekte übernehmen. Man kann sie in einem neuen Browser-Tab ansehen, direkt in den eigenen Workspace importieren, oder einzelne Code-Ausschnitte kopieren.

Dieser Ende-zu-Ende-Workflow eignet sich gut als Vorlage für eigene klassische ML-Projekte (Klassifikation, Regression) mit XGBoost oder scikit-learn – im Gegensatz zu Deep-Learning-Workflows, die andere Werkzeuge nutzen.

Quelle: <https://docs.databricks.com/aws/en/mlflow/end-to-end-example>
Stand: 2026-08-06